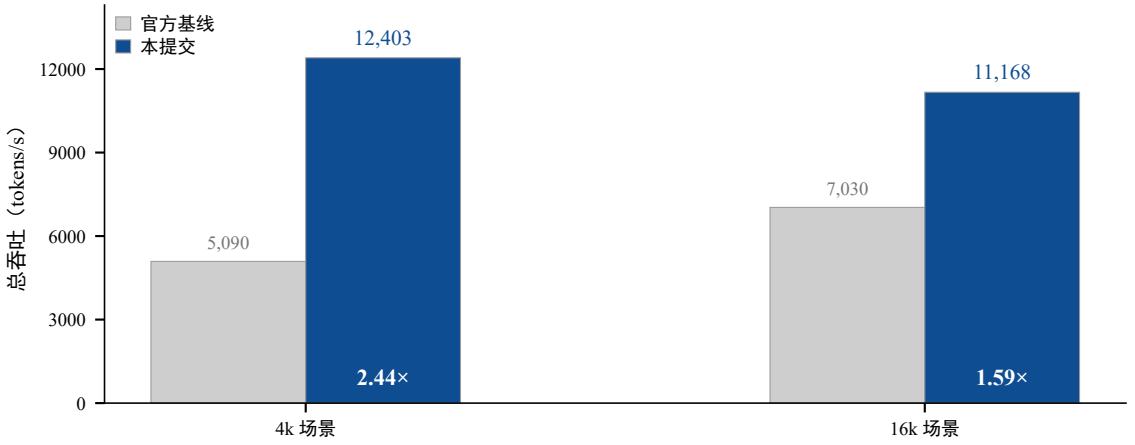
官方基线
本提交
总吞吐（tokens/s）
12000
9000
6000
3000
0
5,090
12,403
2.44×
7,030
11,168
1.59×
4k 场景
16k 场景