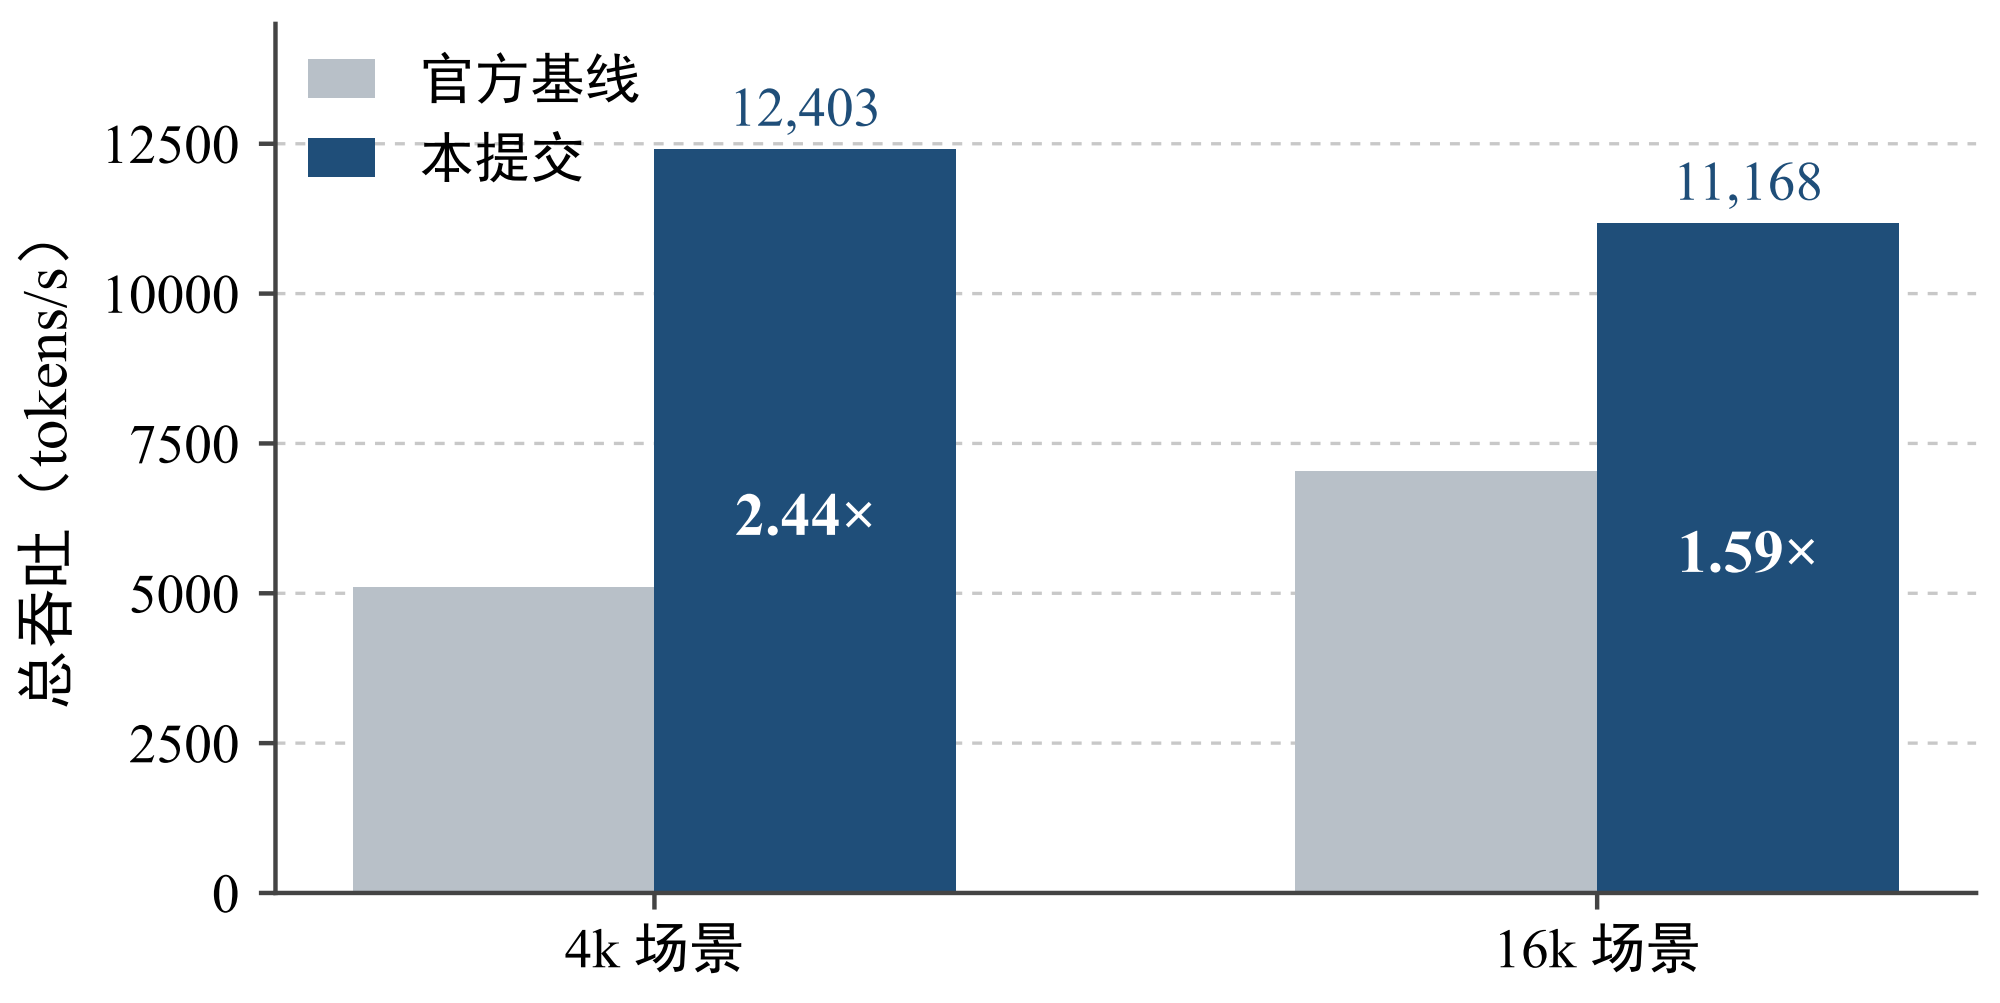
官方基线
本提交
总吞吐（tokens/s）
12500
10000
7500
5000
2500
0
12,403
11,168
2.44×
1.59×
4k 场景
16k 场景