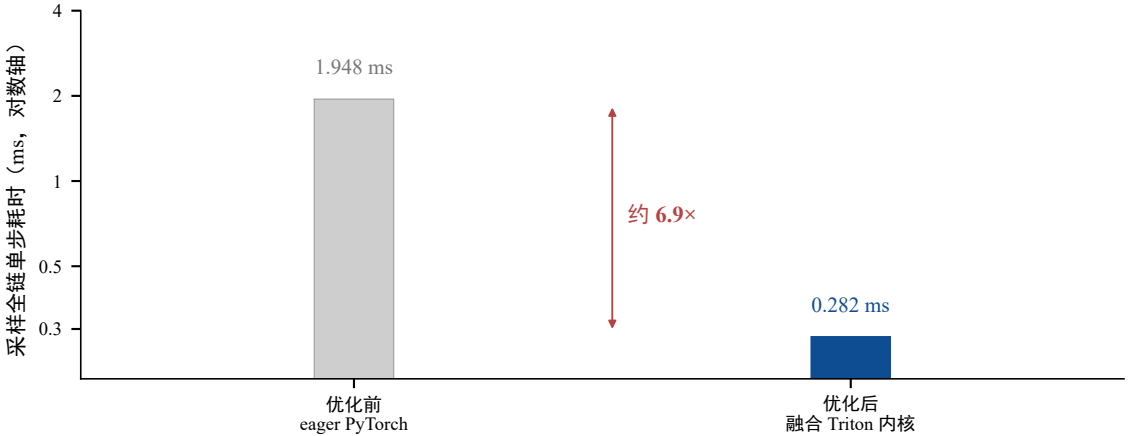
采样全链单步耗时（ms，对数轴）
4
2
1
0.5
0.3
1.948 ms
约 6.9×
0.282 ms
优化前
eager PyTorch
优化后
融合 Triton 内核