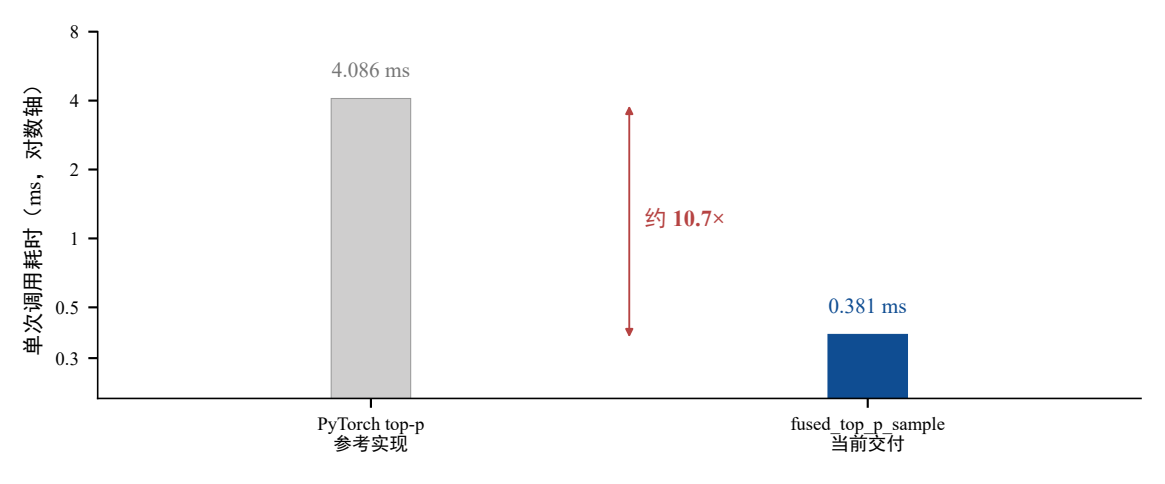
单次调用耗时（ms，对数轴）
8
4
2
1
0.5
0.3
4.086 ms
约 10.7×
0.381 ms
PyTorch top-p
参考实现
fused_top_p_sample
当前交付