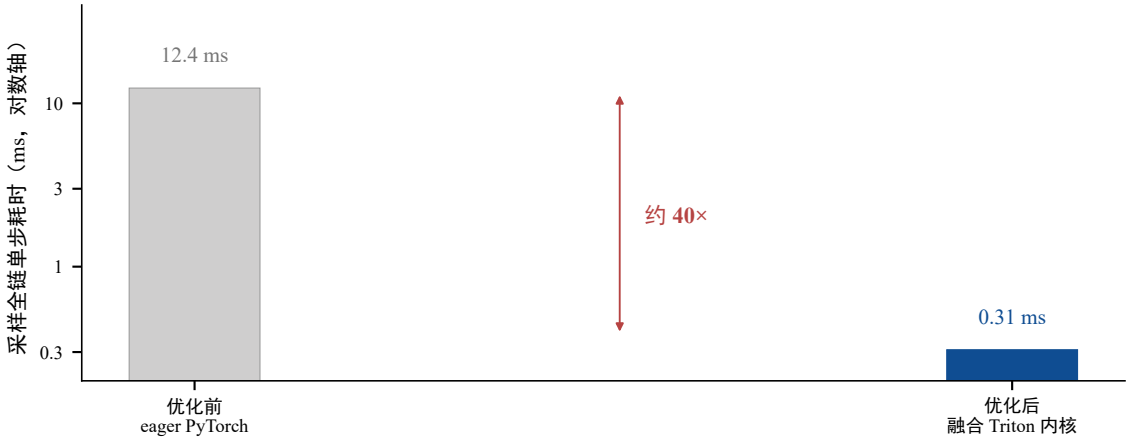
采样全链单步耗时（ms，对数轴）
12.4 ms
10
3
1
0.3
约 40×
0.31 ms
优化前
eager PyTorch
优化后
融合 Triton 内核