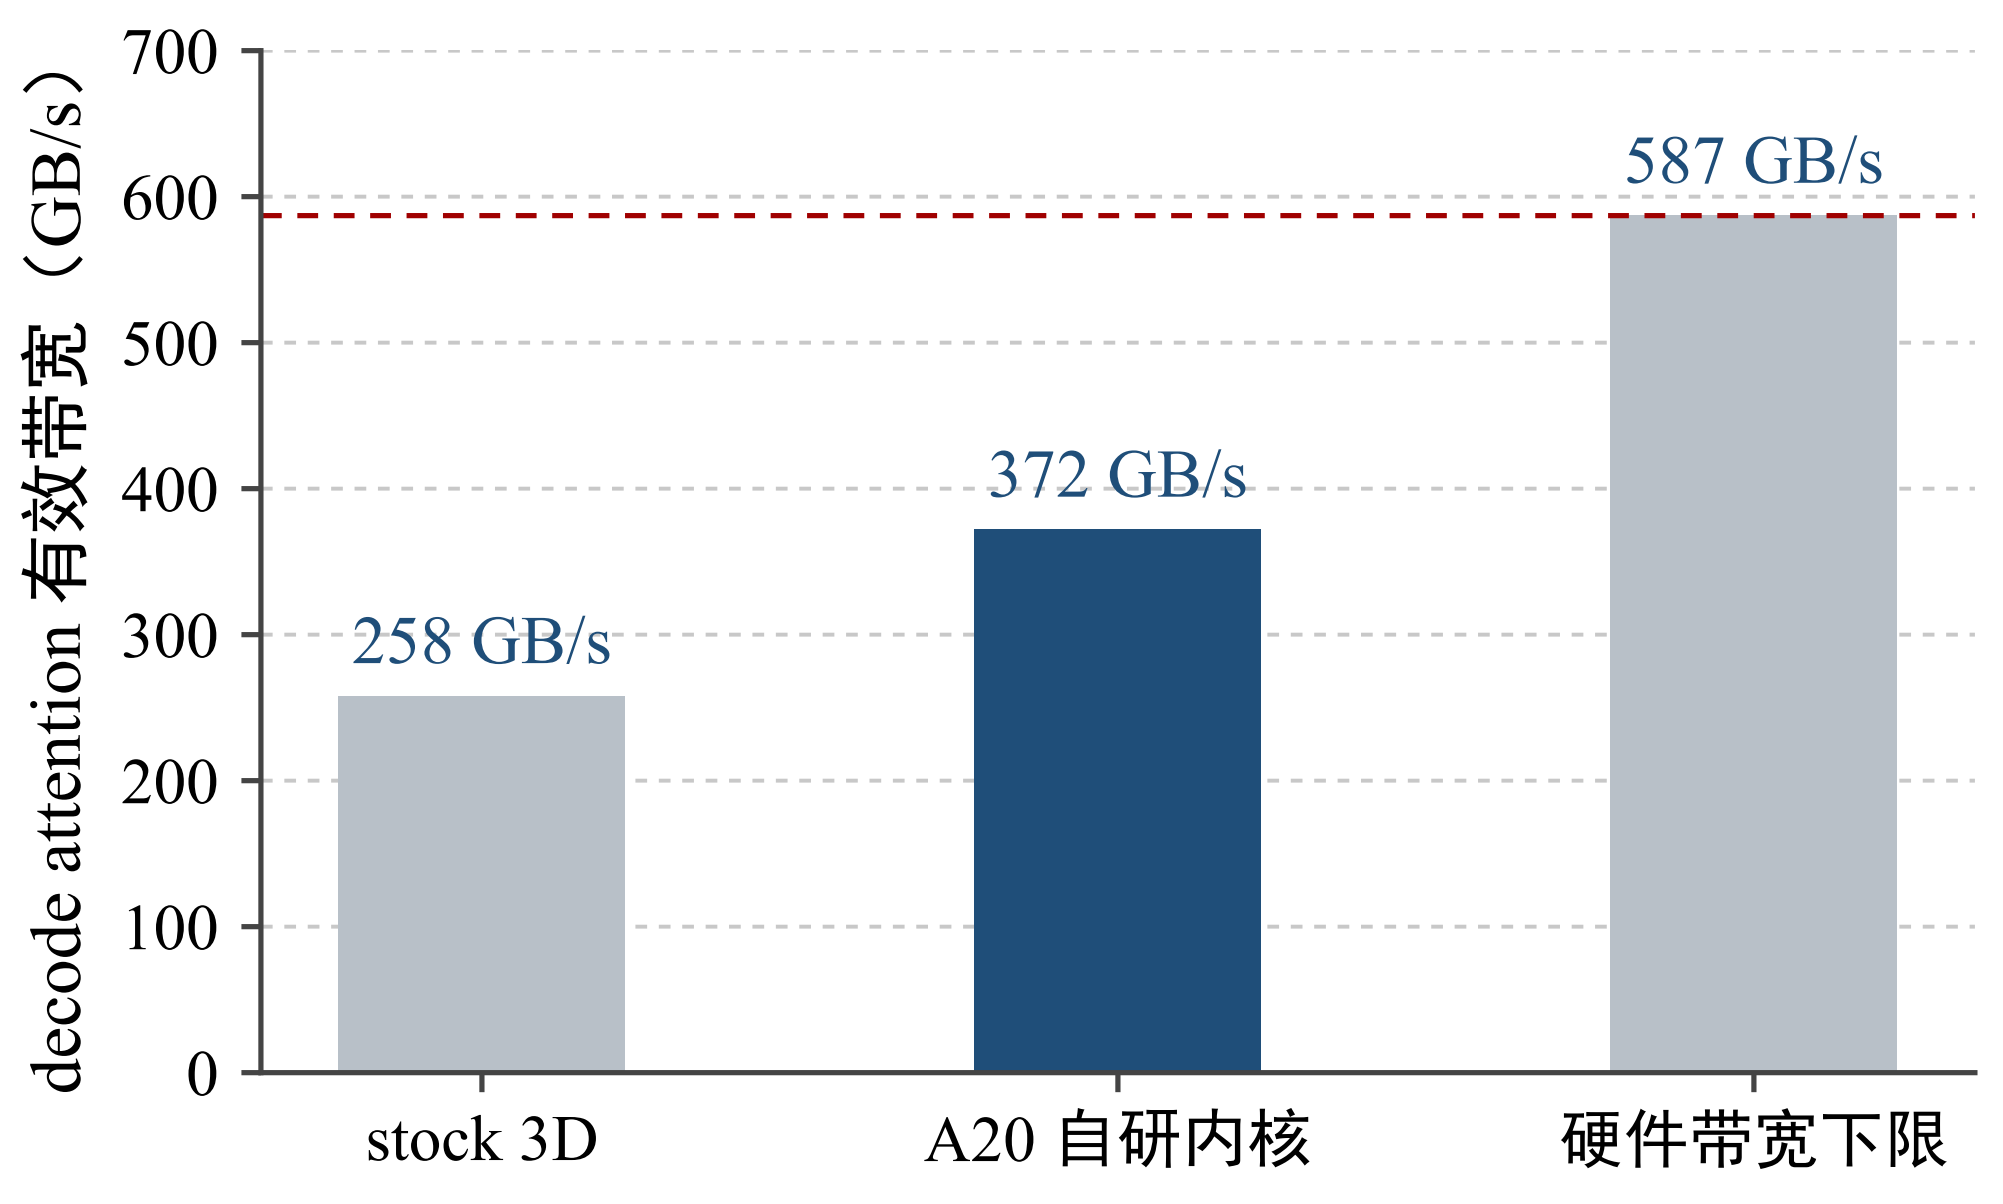
decode attention 有效带宽（GB/s）
700
600
500
400
300
200
100
0
587 GB/s
372 GB/s
258 GB/s
stock 3D
A20 自研内核
硬件带宽下限