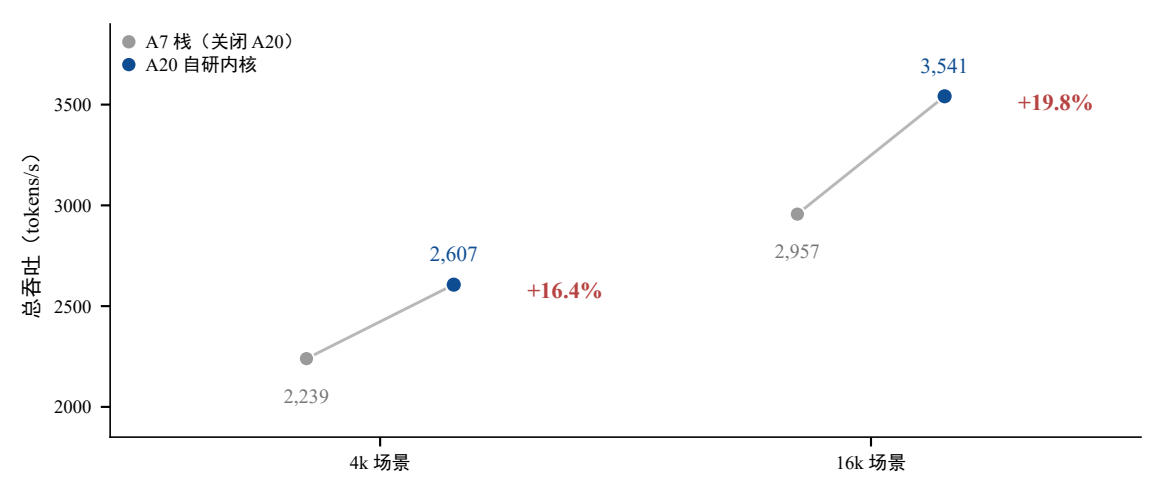
A7 栈（关闭 A20）
A20 自研内核
总吞吐（tokens/s）
3500
3000
2500
2000
2,239
2,607
+16.4%
2,957
3,541
+19.8%
4k 场景
16k 场景