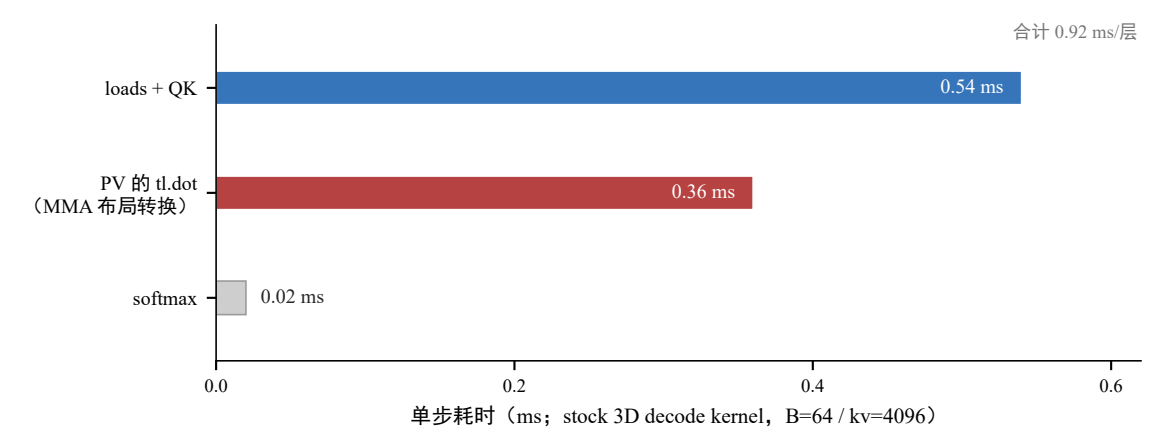
合计 0.92 ms/层
loads + QK
0.54 ms
PV 的 tl.dot
（MMA 布局转换）
0.36 ms
softmax
0.02 ms
0.0
0.2
0.4
0.6
单步耗时（ms；stock 3D decode kernel，B=64 / kv=4096）