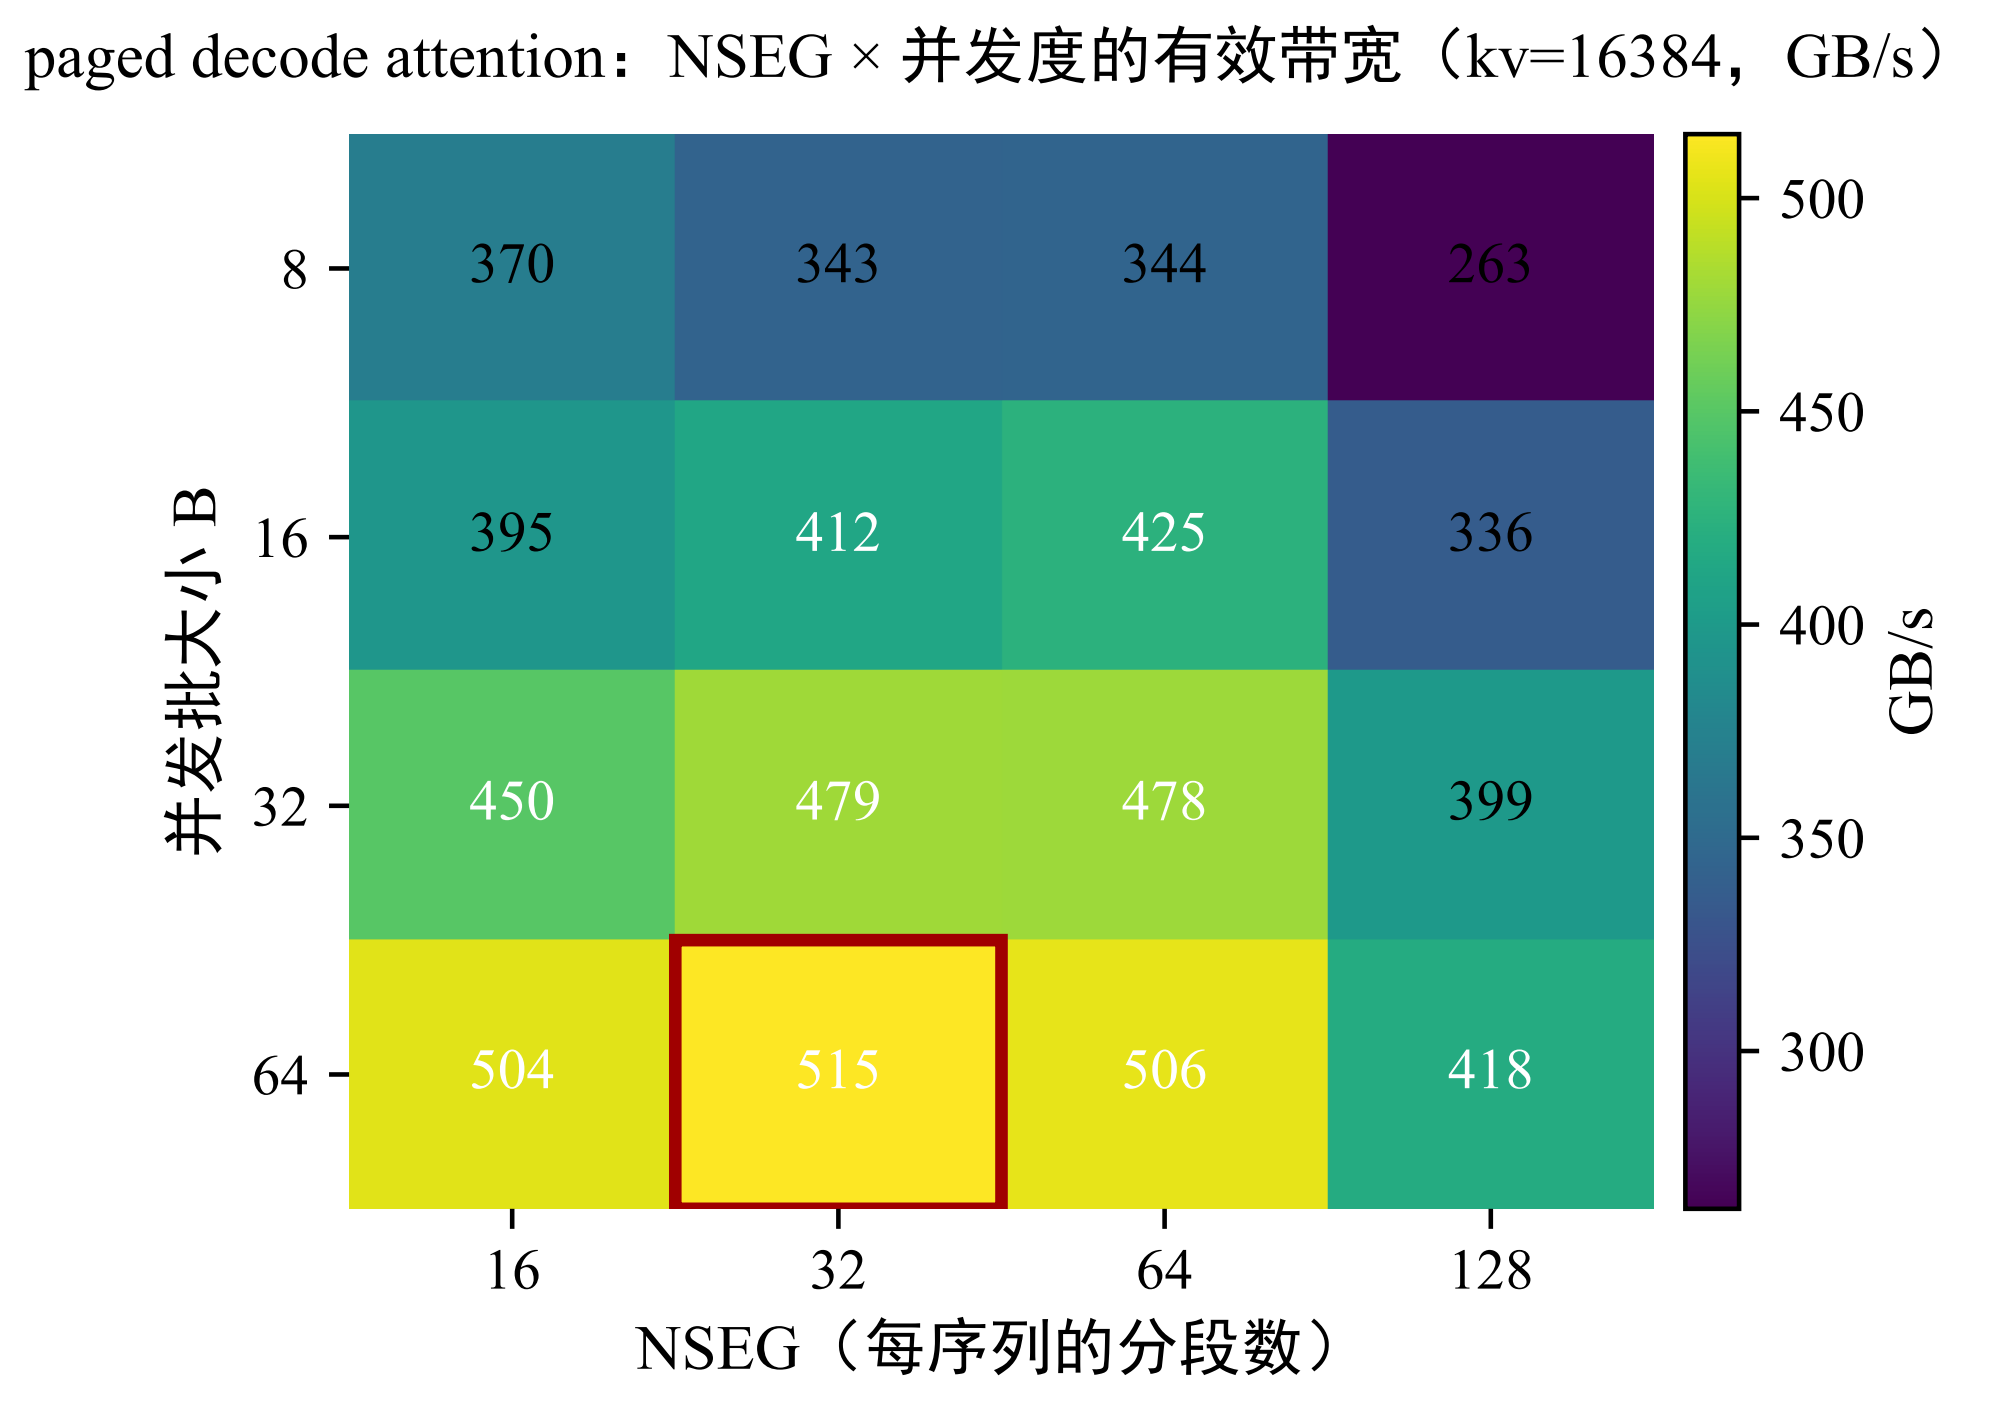
paged decode attention：NSEG × 并发度的有效带宽（kv=16384，GB/s）
并发批大小 B
8
16
32
64
370
343
344
263
395
412
425
336
450
479
478
399
504
515
506
418
16
32
64
128
NSEG（每序列的分段数）
500
450
400
350
300
GB/s