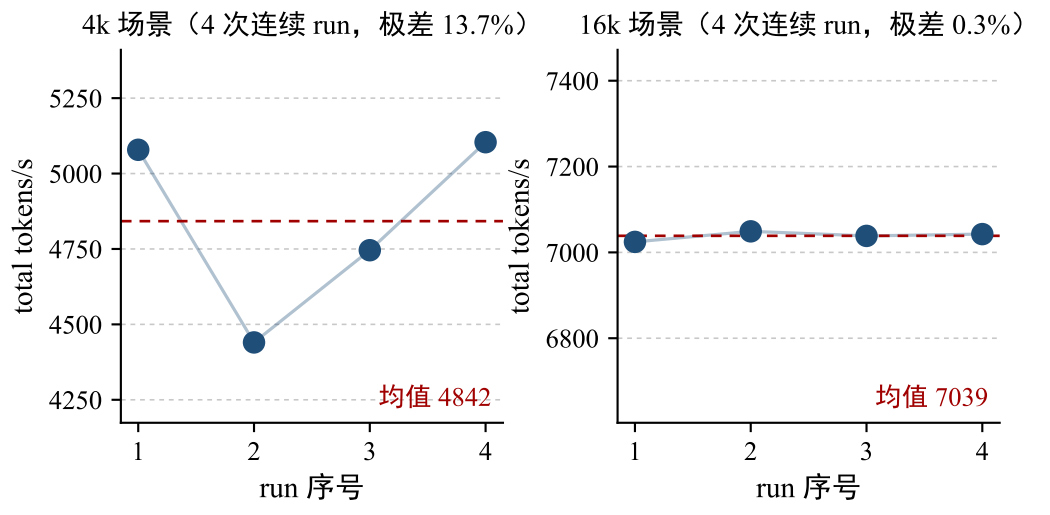
4k 场景（4 次连续 run，极差 13.7%）
total tokens/s
5250
5000
4750
4500
4250
均值 4842
1
2
3
4
run 序号
16k 场景（4 次连续 run，极差 0.3%）
total tokens/s
7400
7200
7000
6800
均值 7039
1
2
3
4
run 序号