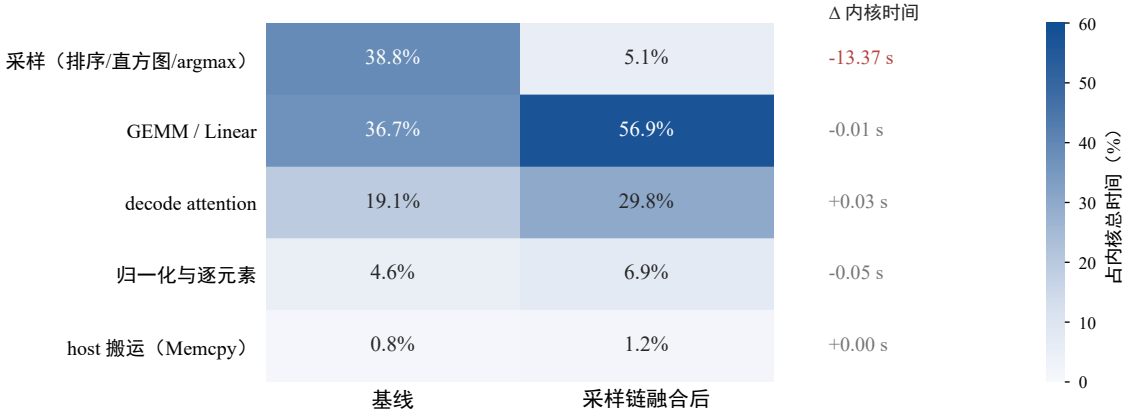
Δ 内核时间
采样（排序/直方图/argmax）
38.8%
5.1%
-13.37 s
GEMM / Linear
36.7%
56.9%
-0.01 s
decode attention
19.1%
29.8%
+0.03 s
归一化与逐元素
4.6%
6.9%
-0.05 s
host 搬运（Memcpy）
0.8%
1.2%
+0.00 s
基线
采样链融合后
占内核总时间（%）
60
50
40
30
20
10
0