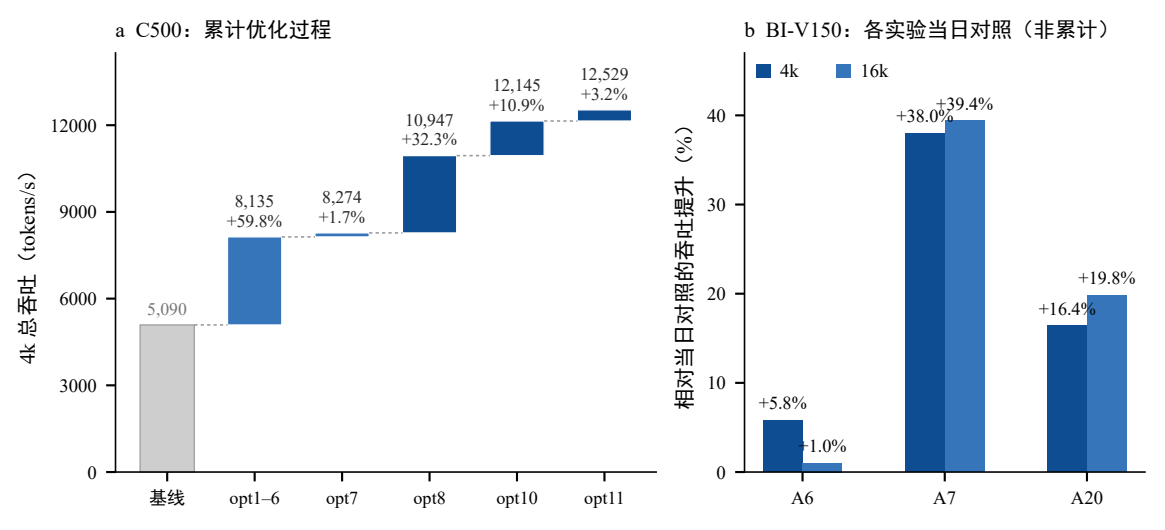
a C500：累计优化过程
4k 总吞吐（tokens/s）
12000
9000
6000
3000
0
5,090
8,135
+59.8%
8,274
+1.7%
10,947
+32.3%
12,145
+10.9%
12,529
+3.2%
基线
opt1–6
opt7
opt8
opt10
opt11
b BI-V150：各实验当日对照（非累计）
4k
16k
相对当日对照的吞吐提升（%）
40
30
20
10
0
+5.8%
+1.0%
+38.0%
+39.4%
+16.4%
+19.8%
A6
A7
A20