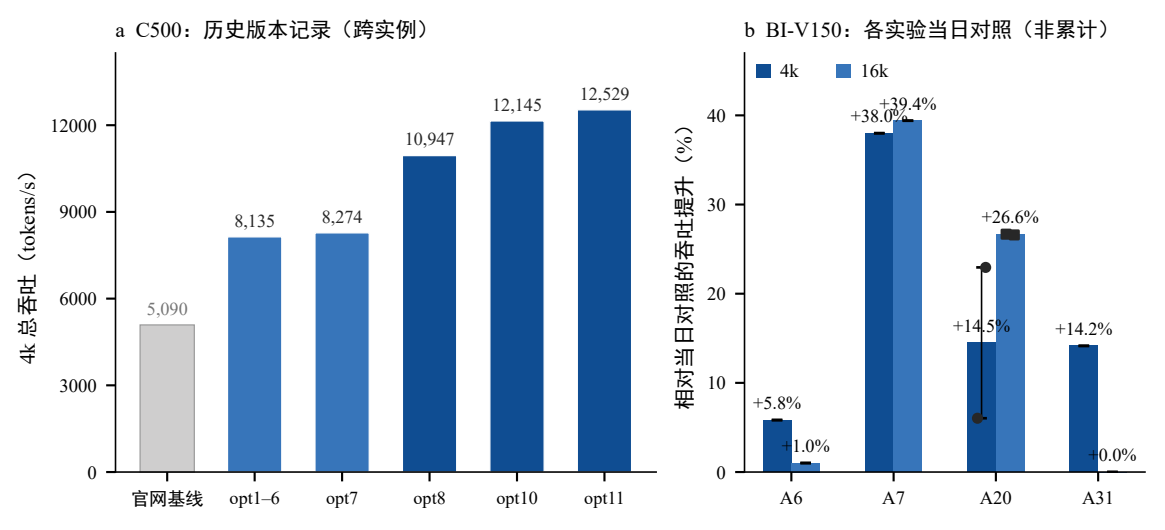
a C500：历史版本记录（跨实例）
4k 总吞吐（tokens/s）
0
3000
6000
9000
12000
5,090
8,135
8,274
10,947
12,145
12,529
官网基线
opt1–6
opt7
opt8
opt10
opt11
b BI-V150：各实验当日对照（非累计）
相对当日对照的吞吐提升（%）
4k
16k
0
10
20
30
40
+5.8%
+1.0%
+38.0%
+39.4%
+14.5%
+26.6%
+14.2%
+0.0%
A6
A7
A20
A31