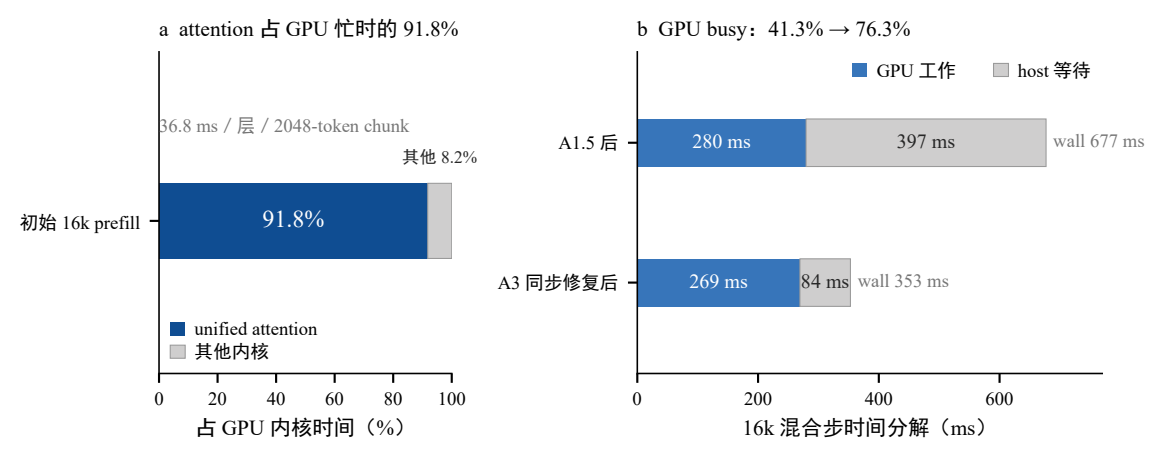
a attention 占 GPU 忙时的 91.8%
36.8 ms / 层 / 2048-token chunk
其他 8.2%
初始 16k prefill
91.8%
unified attention
其他内核
0
20
40
60
80
100
占 GPU 内核时间（%）
b GPU busy：41.3% → 76.3%
GPU 工作
host 等待
A1.5 后
280 ms
397 ms
wall 677 ms
A3 同步修复后
269 ms
84 ms
wall 353 ms
0
200
400
600
16k 混合步时间分解（ms）