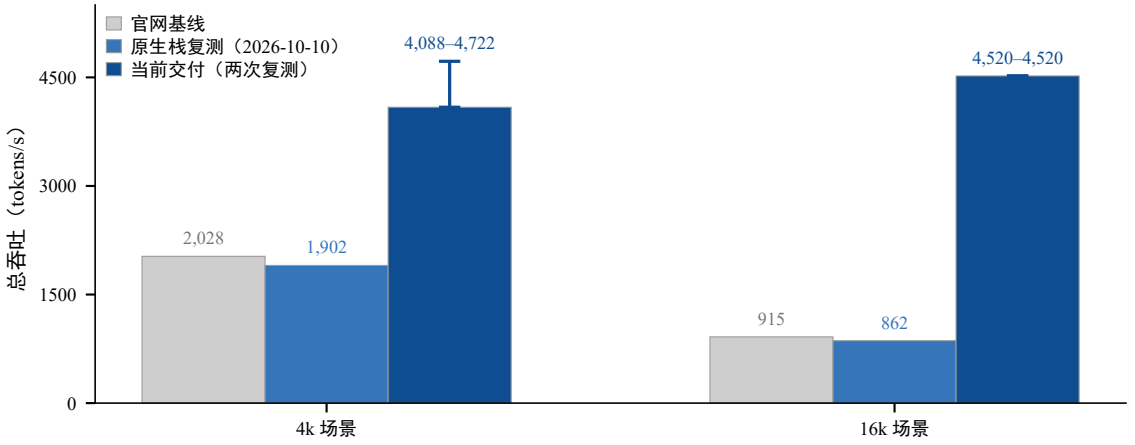
官网基线
原生栈复测（2026-10-10）
当前交付（两次复测）
总吞吐（tokens/s）
4500
3000
1500
0
2,028
1,902
4,088–4,722
915
862
4,520–4,520
4k 场景
16k 场景