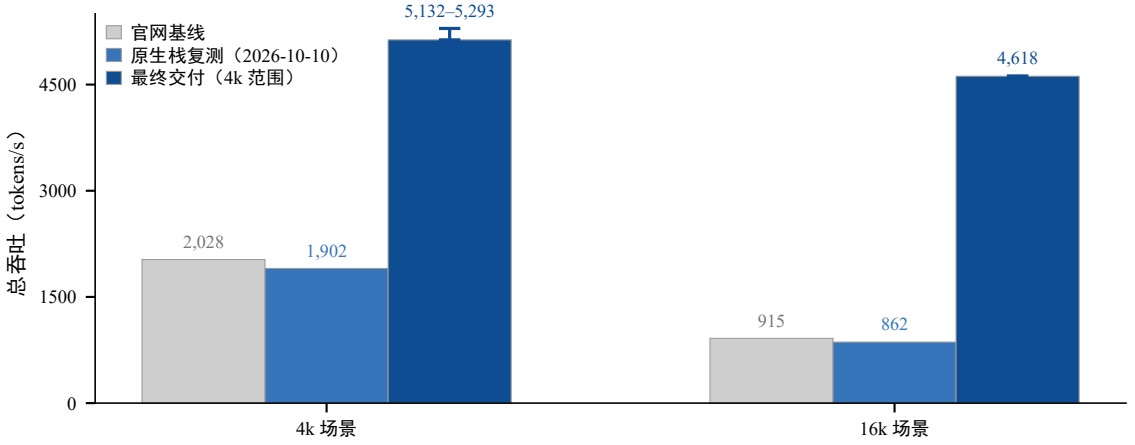
官网基线
原生栈复测（2026-10-10）
最终交付（4k 范围）
总吞吐（tokens/s）
0
1500
3000
4500
2,028
1,902
5,132–5,293
915
862
4,618
4k 场景
16k 场景