MiniCPM5-2B 双国产芯片推理吞吐优化技术报告

——面向天数 BI-V150 与沐曦曦云 C500 的算子、内核与调度优化

赛道：FlagOS 开放计算全球大赛（赛季二）赛道二

队伍：XLANG2026　队员：邓乾（GitHub：xy200303，单人组队）

2026 年 11 月 11 日

摘要

本报告面向国产芯片上的大模型推理吞吐优化任务，在官方指定的 FlagOS 栈上，对 MiniCPM5-2B 在天数 BI-V150 与沐曦曦云 C500 两款芯片开展算子、内核与调度优化，保持 `vllm serve` 启动参数、模型与精度要求不变。天数最终版本已从公开 tag 历史重放到官方镜像实际基线 FlagGems `4df52d91`，避免以公开 tag 的后续提交替代镜像基线。

在已完成的同机复测中，C500 的 4k 与 16k 总吞吐分别为 12527.62 和 11143.77 tok/s，达到官网基线的 2.46 倍和 1.59 倍。天数 BI-V150 的官方开发与评测环境均为 32GB；镜像对齐后，4k 三次独立四轮测量中位数为 5292.46 tok/s，TTFT 为 3908.25 ms，16k 四轮汇总为 4618.41 tok/s，TTFT 为 118761.15 ms，分别达到官网基线的 2.61 倍和 5.05 倍。最终 MATH-500 Level 3 为 98.1%（105/105 成功、0 错误），高于 95% 的赛题要求。

主要优化包括：按输入形状选择 GEMM 与 attention 的实现或执行配置；用 1024-bin 质量直方图实现免排序 top-p 采样；针对 PV 矩阵乘的布局转换开销重写 paged decode attention；通过双累加器 GEMM 融合 SiLU 门控，并将 gate/up 权重预打包为 K 维连续的 tile；通过进程内配置缓存和单表反射减少 host 配置查询与数据库反射开销；减少 prefill 阶段的隐式同步与冗余内核发射。

关键词：国产芯片；推理吞吐；算子融合；paged decode attention；shape-aware dispatch；vLLM

目录

1 引言 **4**

1.1 任务定义 4

1.2 评测口径 4

2 总体结果 **4**

2.1 交付版本与启动验证 5

2.2 性能与约束对照 6

2.3 实验环境 6

2.4 主要技术贡献 8

3 研究方法与实验设计 **9**

3.1 实验标识与证据组织 9

3.2 分析与验证流程 9

4 沐曦 C500：采样链、GEMM 路由与 host 同步消除 **10**

4.1 瓶颈分析 10

4.2 免排序的采样链（C500-opt1 / C500-opt3 / C500-opt7 / C500-opt11） 10

4.3 GEMM 布局与路由（C500-opt2 / C500-opt4 / C500-opt6 / C500-opt8 / C500-opt11） 12

4.4 消除 prefill 每层 DtoH 同步（C500-opt10） 14

5 天数 BI-V150：vendor 接入、发射配置与自研 decode 内核 **15**

5.1 瓶颈分析 15

5.2 prefill attention 与 host 路径（BI-A1 / BI-A3 / BI-A6） 16

5.3 decode unified-attention 发射配置重构（BI-A7） 16

5.4 自研 paged decode attention 内核（BI-A20） 17

5.5 批量一致性与路径检查 19

5.6 配置缓存与单表反射（BI-A31） 21

5.7 双累加器门控融合与 K 连续权重预打包（BI-A48 / BI-A60） 22

6 跨平台结果与组合消融 **23**

6.1 组合有效性与消融分析 23

6.2 跨平台结果对照 24

7 正确性验证 **26**

8 合规对照与复现指南 **26**

8.1 合规对照 26

8.2 复现步骤 26

8.3 复现注意事项 28

9 结论 **28**

A 代码与实验记录索引 **29**

A.1 结果与原始证据对应表 29

A.2 官网基线来源 32

B 内核形状扫描与测量波动 **32**

1 引言

在硬件、框架和模型固定的条件下，推理吞吐主要受内核效率、访存布局、host 发射和同步开销影响。本报告以 MiniCPM5-2B[7] 为对象，在天数 BI-V150 与沐曦曦云 C500 上，基于官方指定的 FlagOS 软件栈（vllm-plugin-FL[5] 与 FlagGems[6]）开展优化。

两种芯片在指令集、访存层次、运行时和算子库方面存在差异，通用 GPU 上的常用配置不一定适用。例如，Triton 默认的 `num_warps=4`，`num_stages=3` 在 BI-V150 的 decode attention 上并非合适选择。优化过程先用 profile 和微基准定位瓶颈，再修改内核或执行路径，最后通过官方 benchmark 和 MATH-500 评测端到端效果。后续章节分别介绍 C500 的采样链与 GEMM 路由、BI-V150 的 attention 接入与 decode 内核，以及正确性和复现方法。

1.1 任务定义

本赛题要求在不改变模型、不降低精度的前提下，提升 MiniCPM5-2B 在两指定国产芯片上的推理总吞吐（total tokens/s）。优化必须落在框架与算子内部，且需具备实际开发量：KV Cache 与动态批处理、算子融合、内核重写、自研量化策略等均在允许范围内；直接 merge 上游分支、修改 benchmark 脚本、或在缺乏算子优化的情况下切换算子均被禁止。

1.2 评测口径

表 1 官方性能评测场景与约束

项目	内容
性能指标	total tokens/s（总吞吐，取 4k 与 16k 两场景平均）
4k 场景	[4096, 1024, 64, 256]（输入长、输出长、并发、请求数）
16k 场景	[16384, 1024, 64, 128]
精度要求	MATH-500 Level 3，基线 0.962，要求 ≥ 0.95
TTFT 要求	不得超过基线的 +1%
启动参数	`vllm serve` 参数必须与基线完全一致

性能数字均由官方 `vllm bench serve` 产生。当前 C500 复测与历史 C500-opt 系列均采用同一服务连续四轮、去首轮后三轮均值；连续运行不保证每轮冷缓存，prefix cache 命中情况逐次查日志。精度数字来自 evalscope 官方原命令的 MATH-500 Level 3 子集（105 题）。

2 总体结果

C500 数据来自同一健康实例、其专用交付提交的完整复测，并同时保留官网基线和本机原生基线。天数 BI-V150 的官方开发与评测环境均为 32GB；相对收益采用同日交错 A/B，避免跨时段漂移的影响。

2.1 交付版本与启动验证

交付代码为插件与算子两个独立仓库中的固定提交，均保留完整 Git 历史，可用 `git log`、`git show` 和 `git diff` 查看改动。

表 2 代码版本与记录入口

组件	仓库 / 分支	固定提交与内容
插件	`xy200303/vllm-plugin-FL integration/vllm-plugin-fl`	`b5793cd4`；双平台路由、BI-A20 框架 hook 与 BI-A48 MLP 接入
算子	`xy200303/FlagGems integration/flaggems`	`ef516137`；基于镜像 `4df52d91`，含采样、GEMM、paged decode attention、配置缓存、A60 与测试
文档	`xy200303/minicpm-flagserve main`	报告、实验台账、复现脚本；不承担运行时代码

C500 的 4k / 16k 性能数据采集于 2026-11-01，使用插件 `0207b7e1`、FlagGems `9c06143c`（已含 A31 配置缓存）；两次 MATH-500 采集于 2026-10-25，使用插件 `0207b7e1`、FlagGems `aff68555`。两个版本均完成官方四轮 benchmark，日志包含 `mcblas_mm` 注册、采样融合和 lm_head nn 路由。C500 启动耗时受 autotune 缓存影响，实测记录跨度约 127–1129 秒、原生基线为 161 秒，不能用单值估计。最终源码此后回到官方镜像基线（两者相差的 7 个公开 tag 提交不触及 Metax 执行路径），并追加 Iluvatar 专用 A48 / A60 与换行规范化，C500 执行路径未变；但 C500 未在最终提交上重跑，因此表中 C500 数值对应上述实测提交，不冒充最终源码的逐字节复测。

表 3 官网基线、原生栈复测与本提交实测的总吞吐（tok/s）

平台	场景	官网基线	原生栈复测	本提交实测	相对官网
沐曦 C500	4k	5089.645	4210.20	12527.62	2.46×
沐曦 C500	16k	7029.675	5867.59	11143.77	1.59×
天数 BI-V150	4k	2028.01	1902.15	5292.46	2.61×
天数 BI-V150	16k	915.15	861.98	4618.41	5.05×

原生栈复测均使用未修改的官方栈、官方启动命令和四轮去首均值：C500 原生基线测于 2026-10-25，其性能实测采集于 2026-11-01；BI-V150 原生基线测于 2026-10-10（32GB 官方实例）。BI 原生数据及逐轮值见 `docs/baselines/iluvatar-biv150/a1-iluvatar-vendor-fa.md`。C500 的 2.98× / 1.90× 是跨日期参考，不替代官网基线和同日 A/B；BI 的交付数据与原生基线同样不视为同日对照。

注意，total tok/s 同时计入输入与输出，且 4k / 16k 的请求数分别为 256 / 128，不能用该指标直接比较单请求速度。以 BI-V150 第一组为例，两场景总 token 分别为 1.31M / 2.23M，

因此 16k 总吞吐可接近 4k；同组 decode 输出吞吐则由 817.58 降至 265.89 tok/s，TTFT 由 4.33 s 增至 111.64 s，长上下文成本体现在这些分项指标中。

C500 的本机原生基线为 4k 4210.20、16k 5867.59 tok/s，C500 实测相对其分别为 2.98× 和 1.90×。C500 两次 MATH-500 Level 3 均为 98.1%，BI 最终栈为 98.1%，每次均 105/105 请求成功。C500 的 4k TTFT 为 1623.73 ms（官网基线 3199.435 ms），16k TTFT 为 17961.76 ms（官网基线 27197.135 ms）；BI 的 4k TTFT 为 3908.25 ms，16k TTFT 为 118.76 s（官网基线分别为 11573.53 ms 和 599262.03 ms）。按官网基线判断，两平台各场景均满足 TTFT 不超过 baseline +1% 的约束。

BI 的首次 4k 测量为 5131.78 tok/s，之后两次稳定态四轮测量为 5292.46 和 5292.99 tok/s；表 3 采用三次独立测量的中位数并保留首测值，避免只展示高值。16k 只执行一次完整四轮测量，四轮汇总为 4618.41 tok/s。

2.2 性能与约束对照

图 1 汇总吞吐、精度和 TTFT 相对裕度。吞吐与 TTFT 取相对基线的改善百分比，精度取相对 0.95 门槛的提升幅度。C500 四项数值为 +146.1% / +58.5% / +3.3% / +34.0%，BI-V150 为 +161.0% / +404.7% / +3.3% / +80.2%。

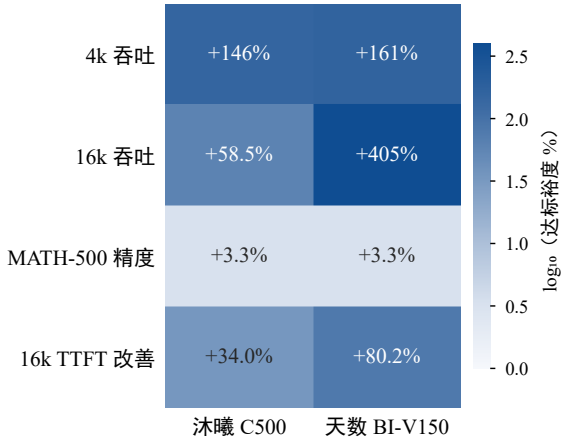
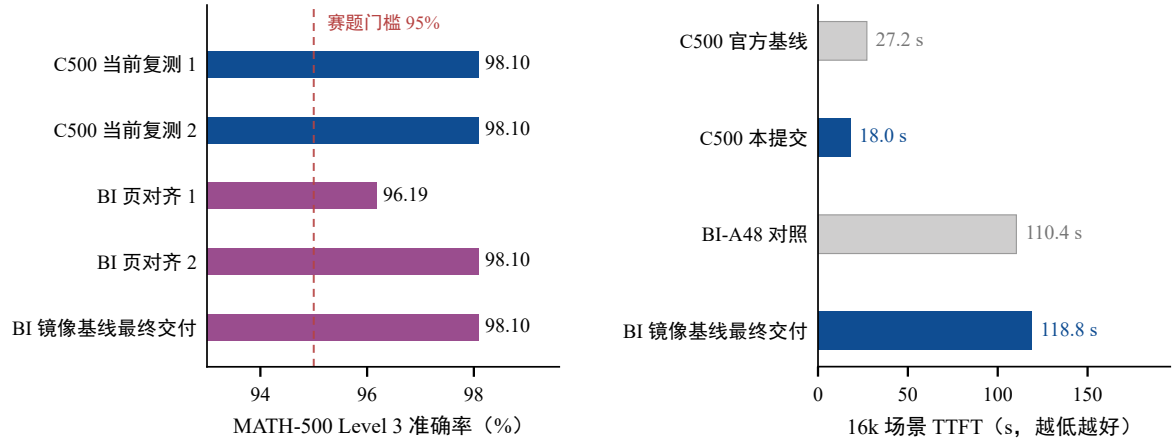


图 1 四项硬约束的达标裕度（相对各自门槛的百分比，颜色取 $\log_{10}$）

2.3 实验环境

表 4 列出最终复测环境。硬件容量、驱动与运行时来自实例管理接口，依赖版本来自 Python 包信息；BI-V150 的 Triton 版本采用运行时 `triton.__version__` 读数。两平台各自使用已完成的实测提交：C500 性能为插件 `0207b7e1` / FlagGems `9c06143c`，C500 精度为 `0207b7e1` / `aff68555`；BI 为 `58bae94` / `85b4ba82`。最终分支在这些测量之后只追加 Iluvatar 专用改动与换行规范化。



(a) MATH-500 Level 3 精度与合格线 (b) 16k 场景 TTFT（越低越好）

图 2 精度与延迟两项约束的对照：四个平台 / 场景组合均达标

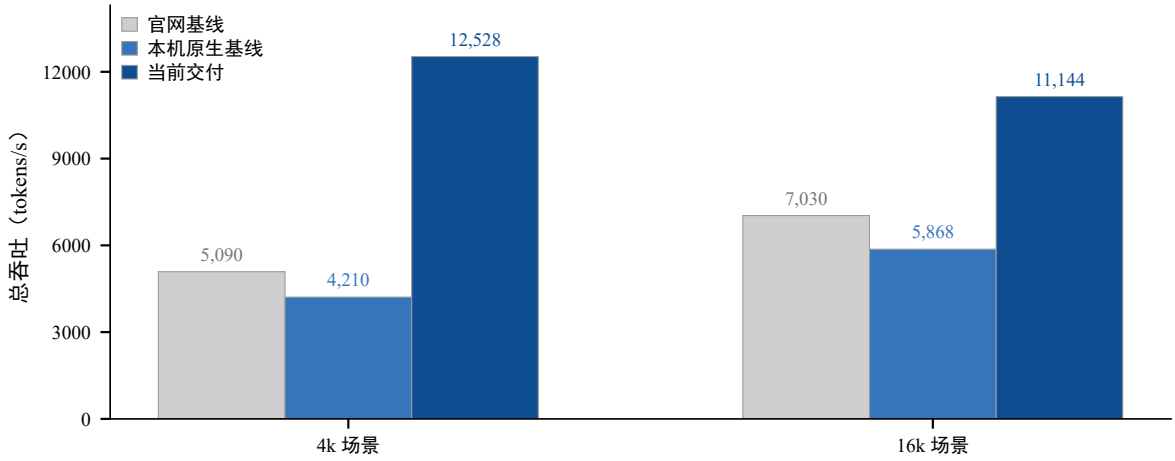


图 3 沐曦 C500：官网基线、本机原生基线与 C500 实测版本的四轮去首均值对比

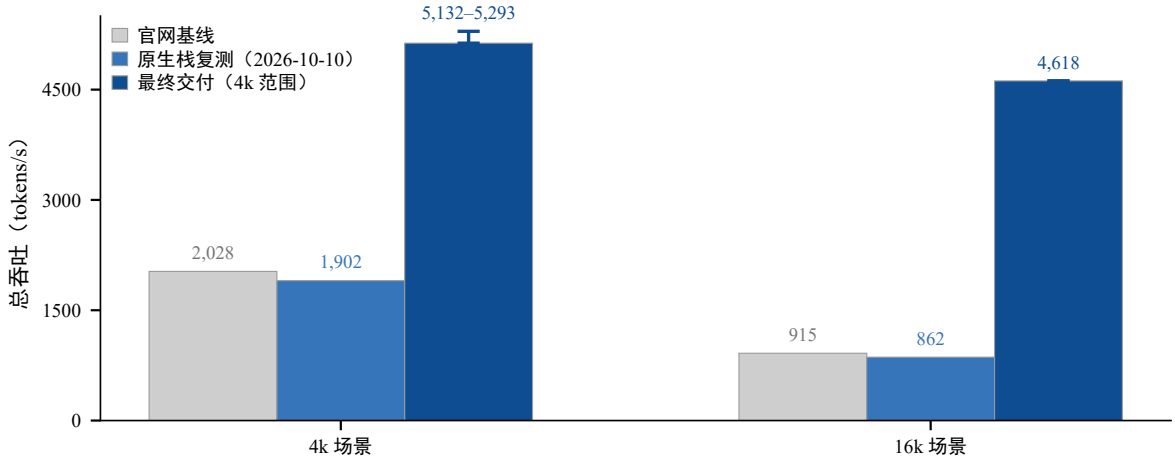


图 4 天数 BI-V150：官网基线、历史原生栈复测与镜像对齐后的最终交付对比；误差线给出 4k 三次独立四轮测量的范围，16k 为单次四轮汇总

表 4 双平台最终复测的软硬件环境

项目	天数 BI-V150	沐曦曦云 C500
GPU / 显存	BI-V150 / 32GB	C500（104 SM）/ 64GB
CPU	Intel Xeon Gold 6330 @ 2.00GHz	Intel Core i7-8550U
CPU 内存 / Swap	503GiB / 8GiB	128GiB / 无
实例与镜像	FlagOS 线上实验室官方环境	模力方舟，FlagOS 2.1
PyTorch	2.10.0+corex.4.5.0	2.8.0+metax3.7.0.7
vLLM	0.24.0	0.24.0
Triton	3.6.0	3.0.0+metax3.7.0.7
芯片软件栈	IX-ML 4.4.0；驱动 4.5.0	MACA 3.7.0.38；驱动 3.8.30
FlagTree	0.6.2a3+iluvatar3.6	不适用
evalscope	1.11.1	1.11.1
插件 / FlagGems	b5793cd4 / ef516137	b5793cd4 / ef516137
最终复测日期	2026-11-11（镜像对齐）	2026-10-25 至 2026-11-01

C500 的 CPU 内存是本团队实例的实测复现条件，不是官网公布的评测规格；CPU 型号来自同镜像开发实例记录，最终复测 manifest 未重复采集该字段。64GB CPU 内存实例上原生镜像也曾发生启动期 OOM，因此复现说明单独保留这一现象与内存建议。BI-V150 的 32GB 指 GPU 显存，不能与 CPU 内存混淆。

天数最终分支从官方镜像的 FlagGems `4df52d91`（镜像内 `v5.3.5`）重放，而不是使用公开 tag 额外包含的 7 个提交。插件集成分支的祖先与镜像 `13eb9be` 一致，无需迁移。重放记录、冲突处理、测试与最终复测见 `docs/experiments/runs/image-baseline-align/`。

2.4 主要技术贡献

本提交的技术路线由以下五部分组成，详细实现和实验分别见第 4、5 章。

（1）面向芯片与输入形状的执行路径选择。不假定同一 GEMM 或 attention 配置在所有形状上最优，而是在保留原实现的前提下，按 M、KV 页尺寸和 prefill / decode 类型选择 vendor 库或 Triton 内核。C500 侧重 lm_head 与 prefill GEMM 的布局、库调用和 host 元数据路径；BI-V150 侧重 warp 级发射配置与 attention 实现。路由之外还包含权重复本、布局转换、同步消除和页对齐访问等代码改动。

（2）免排序 top-p 采样与温度折叠。将 bf16 logits 读取、top-p 阈值估计、掩码与 Gumbel-Max 合并，避免对 130560 词表进行完整排序。阈值由 1024-bin 质量直方图定位并保守取 bin 下沿；温度通过 $\arg\max(x/T+g)=\arg\max(x+Tg)$ 折叠进采样分数。该路径直接作用于每步解码末尾的采样热点。

（3）减少 PV 布局转换的 paged decode attention。针对 BI-V150 上 PV 矩阵乘的累加器到操作数布局转换，将并行单元组织为 warp 内的（序列、KV 头、分段）计算，配合单 warp 发射、base-2 在线 softmax 和分段归并。段边界与 KV 页对齐后，页号在段内保持标量，省去逐 token 除模和向量页 gather；段长由设备端 `seq_lens` 计算，分段缓存在图捕获前分配，以兼

容 FULL_DECODE_ONLY。

（4）面向配置与 host 路径的开销消除。对同一 shape 的算子配置查询和缺失结果做进程内缓存，避免重复访问配置数据库；将新配置模型的全库 automap reflection 改为只加载目标表。该路径不改变算子选择、数值语义或启动参数，直接减少执行线程中的配置与元数据开销。

（5）门控融合与权重 tile 预打包。 BI-A48 以两个 FP32 累加器共享输入 tile，直接输出 SiLU 门控结果；BI-A60 进一步把 gate/up 权重预打包为 K 维连续的 $BK \times BN$ tile，使加载布局匹配 BI-V150 的 `tl.dot` 后端。预打包只执行一次并缓存，不在 decode 稳态重复转换权重。

3 研究方法与实验设计

3.1 实验标识与证据组织

全文统一采用“平台前缀＋实验编号”标识：`C500-optN` 表示沐曦 C500 的第 N 项优化，`BI-Axx` 表示天数 BI-V150 的第 xx 项实验。编号仅用于对应代码、日志和原始证据，不表示两个平台之间存在一一对应关系，也不直接代表累计收益。表格中的 A1/A2、B1/B2 仅表示同日交错对照的重复轮次，不属于上述实验编号。

两种芯片采用相同的分析与验证流程，测试脚本、profile、日志和 benchmark CSV 按实验编号保存。

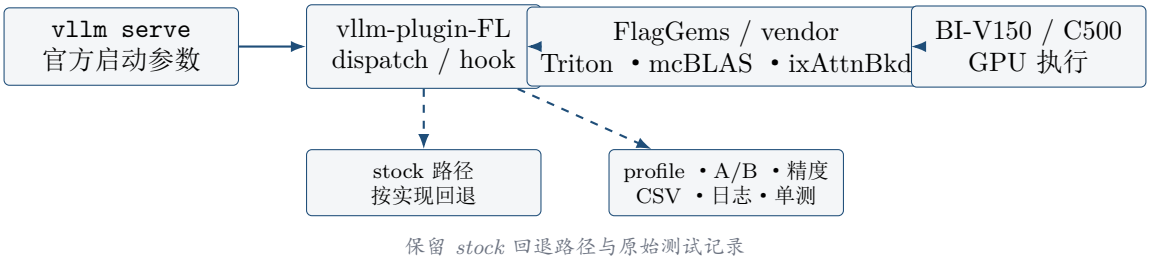


图 5 插件、算子实现与测试记录之间的关系

算子本体位于 FlagGems，框架接入位于 vllm-plugin-FL。性能测试使用官方 benchmark，精度测试使用 evalscope，内核测试与实现文件按附录索引对应。BI-A20、vendor prefill 和不支持的采样特征保留回退路径；mcBLAS 返回码采用断言检查，不属于异常自动回退。

3.2 分析与验证流程

（1）Profile 定位：结合 serve 时序日志（PagedAttention 式分页 KV 管理见文献 [2]）、设备计时与 host 打点，区分 GPU 内核、host 发射和隐式同步开销；（2）独立测试：新内核先检查目标形状的数值结果，再接入 serve；（3）Shape-aware dispatch：按输入形状选择等价实现或执行配置；（4）端到端测试：保持官方 serve 参数，检查吞吐、TTFT 和 MATH-500 精度。

BI-A6 双 gather、BI-A7 发射配置要求逐位一致；采样融合与 GEMM 路由检查分布和数值误差，并复测 MATH-500。不满足精度要求的改动不进入交付分支。

4 沐曦 C500：采样链、GEMM 路由与 host 同步消除

4.1 瓶颈分析

初始 profile 显示，C500 的主要开销集中在采样、GEMM 和 attention。采样尾部采用 eager PyTorch 实现，包括 bf16→fp32 cast、温度缩放、130560 词表排序和 gumbel-argmax；部分 GEMM 存在布局与路由失配；prefill 的隐式 DtoH 同步则造成 GPU 空闲。

图 6 将 C500-opt1 前后同一基准（641 步）两次 profile 的 GPU 内核时间按算子族聚合（源：`docs/baselines/metax-c500/profile_baseline.txt` 与 `profile_post_opt1.txt`）。采样族由 14.61 s 降至 1.24 s，占内核时间的比例由 38.8% 降至 5.1%；GEMM 与 attention 的绝对时间分别为 13.82→13.81 s、7.19→7.22 s。该图不代表 C500-opt11 最终 profile，后续优化分别针对 GEMM 路由、attention 和 prefill 同步展开。

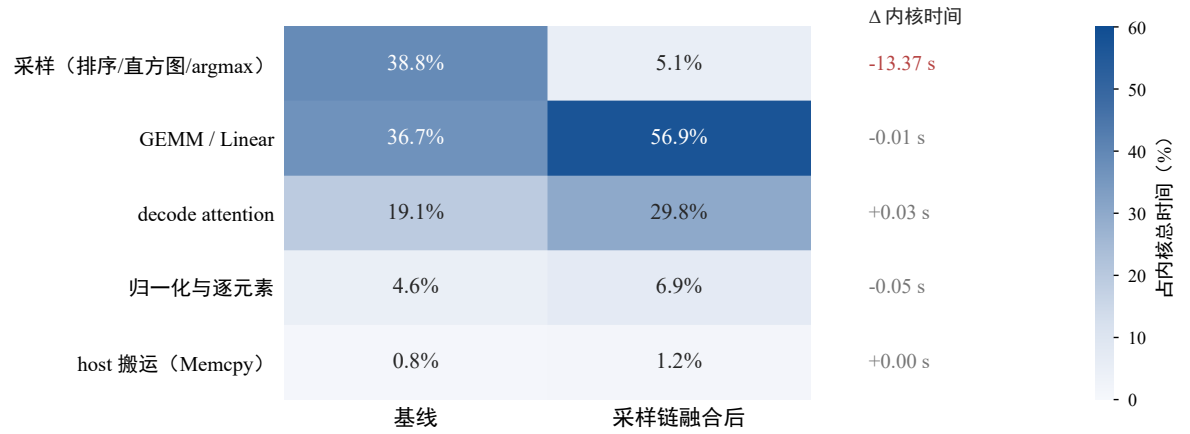


图 6 C500-opt1 前后热路径的算子族构成：按内核时间占比（右列为绝对时间变化）

4.2 免排序的采样链（C500-opt1 / C500-opt3 / C500-opt7 / C500-opt11）

采样链由自研 Triton 内核 `FlagGems/fused/sampler_fused.py` 与 `top_p_sample.py` 实现，包括三项优化：（1）直接读取 bf16 logits，将温度折叠进 Gumbel-Max[4]，利用 $\arg\max(x/T+g) = \arg\max(x+Tg)$，并在 $T < 10^{-5}$ 时退化为 $\arg\max$；（2）以单轮 1024-bin 质量直方图定位 top-p 阈值 τ 所在 bin，并保守取 bin 下沿，在忽略 $\exp(-60)$ 截断尾质量的近似下保证保留集质量不小于 $p \cdot Z$；（3）在官方 B=64 形状下采用词表维 split-parallel（32 splits × BLOCK 4096）。2026-10-25 在 C500 实测代码上复测，B=64、词表 130560 时，同语义 PyTorch top-p 对照为 4.086 ms，`fused_top_p_sample` 为 0.381 ms，加速约 10.7 倍。

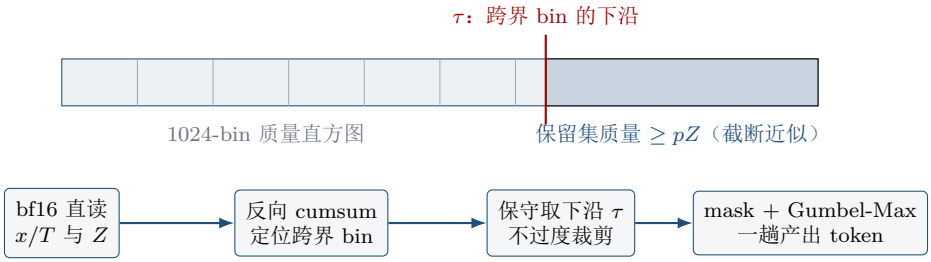


图 7　免排序 top-p 采样链示意图（流程与阈值规则为代码语义，非另造的分布数据）

图 7 中的阈值取所在 bin 的下沿；忽略 $\exp(-60)$ 截断尾质量时，保留集质量不小于 pZ，因此该下界带截断近似限定。采样分数写成 $x+Tg$，与先算 x/T 再加 g 的 argmax 等价。对应实现如下。

top_p_sample.py:180--198：反向 cumsum 定位阈值并保守取下沿

```
180     mass_rev = tl.load(HIST + row * NBINS + (NBINS - 1 - offs))
181     cum = tl.cumsum(mass_rev, axis=0)
182     z = tl.load(Z_ROW + row)
183     p = tl.load(P + row).to(tl.float32)
184     lo = tl.load(LO + row)
185     hi = tl.load(HI + row)
186     w = (hi - lo) / NBINS
187
188     target = p * z
189     reach = cum >= target
190     # crossing bin b*: cum-from-top first reaches target there;
191     # sum(reach) == b* + 1 (reversed positions r*..NBINS-1 all reach)
192     b = tl.sum(reach.to(tl.int32), axis=0) - 1
193     b = tl.minimum(tl.maximum(b, 0), NBINS - 1)
194     # conservative: tau = lower edge of crossing bin => mass{x>=tau} >= target
195     new_lo = lo + b * w
196     new_hi = new_lo + w
197     if FINAL:
198         tl.store(TAU + row, new_lo)
```

top_p_sample.py:241--249：温度折叠的 Gumbel-Max 与 top-p mask

```
241         keep = xs >= tau
242         u = tl.rand(row_seed, step * vocab_padded + idx.to(tl.int32))
243         u = tl.minimum(tl.maximum(u, 1e-20), 1.0 - 1e-7)
244         g = -tl.log(-tl.log(u))
245         score = tl.where(keep, x + noise * g, float("-inf"))
246         tile_best = tl.max(score, axis=0)
247         tile_arg = tl.argmax(score, axis=0)
248         take = tile_best > best
249         best_idx = tl.where(take, start + tile * BLOCK + tile_arg, best_idx)
```

正确性方面，greedy 与 `torch.argmax` 完全一致；top-p 样本全部落在核集内（含直方图粒度 slack），与原实现的 TV 距离处于纯采样噪声区间。

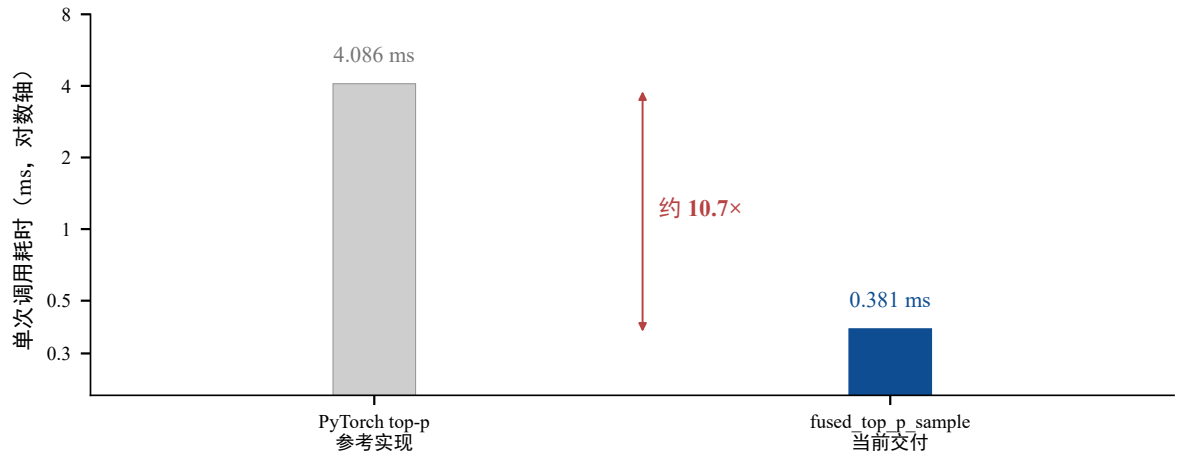


图 8 C500 实测 top-p 采样与同语义 PyTorch 对照（B=64，30 次中位数，对数坐标）

4.3 GEMM 布局与路由（C500-opt2 / C500-opt4 / C500-opt6 / C500-opt8 / C500-opt11）

MACA Triton `mm_kernel` 的高性能流水主要适配 nn 布局。在 prefill 大 M 的 126 组配置扫描中，其耗时为 vendor mcBLAS 的 1.35–1.67 倍；四种 prefill 形状的 vendor 计算吞吐约为 152–197 TFLOPS。FlagGems 接管 `aten::mm` 后，原路由无法直接调用 vendor GEMM。为此，prefill 大 M 通过 ctypes 调用 libmcblas 的 `mcblasGemmEx`（cuBLAS 兼容 ABI），并注册为 custom op 以适配 compiled 区域。默认配置为双布局：小 M（默认阈值 192）或缺少 nn 副本时回退 `F.linear`，大 M 按路由使用 Triton nn 或 mcBLAS；仅保留 nn_db 副本的单布局配置可选，但不是默认。另修复 `vocab_parallel_embedding` 在 import 时绑定原版 `dispatch_unquantized_gemm` 导致 lm_head 未进入优化路由的问题。2026-10-25 复测该形状时，FlagGems Triton 为 667 μs，直接 mcBLAS 为 430 μs（1.55×）；同次原生 `torch.mm` 为 385 μs，说明 mcBLAS 的收益是相对于 FlagGems 路径，而不是超过所有 vendor 实现。

只有已经生成 nn 副本且形状满足条件的线性层才进入新路径。lm_head 通过独立的 `_fl_always_nn` 标志使用 nn 副本，避免被通用 N 上限排除。

linear_nn_repack.py:112--136：按形状在 vendor、Triton 与 stock 之间路由

```python
def _metax_unquantized_gemm(layer, x, weight, bias):
    wn = getattr(layer, "_fl_w_nn", None)
    if wn is not None and bias is None and x.dim() >= 2:
        m = x.numel() // x.shape[-1]
        if (
            getattr(layer, "_fl_always_nn", False)
            or m > _FL_NN_MIN_M
            or weight.numel() == 0
        ):
            x2 = x.reshape(-1, x.shape[-1])
            # Vendor mcBLAS beats the Triton nn kernel 1.35-1.67x at prefill
            # M (sweep_mm_prefill.py); FlagGems' process-wide aten override
            # makes the vendor library unreachable through torch.mm, so the
            # ctypes-bound custom op is the only way to reach it.
            if (
                _mcblas is not None
                and _mcblas.AVAILABLE
                and wn.dtype == torch.bfloat16
                and x2.is_contiguous()
            ):
                out = _mcblas.mcblas_mm(x2, wn)
            else:
                out = torch.mm(x2, wn)
            return out.view(*x.shape[:-1], wn.shape[1])
    return torch.nn.functional.linear(x, weight, bias)
```

ctypes 绑定把行主序的 $C = AB$ 转写成列主序的 $C^T = B^T A^T$，因此不需要改变模型的数学结果；`register_fake` 让编译器在 fake tensor 阶段仍能推导输出形状。

mcblas_mm.py:85--103：直接调用 mcBLAS，保持原 GEMM 语义

```
85  def _mm_impl(a: torch.Tensor, b: torch.Tensor) -> torch.Tensor:
86      M, K = a.shape
87      K2, N = b.shape
88      assert K == K2
89      out = torch.empty(M, N, device=a.device, dtype=torch.bfloat16)
90      st = _lib.mcblasSetStream(
91          _handle, ctypes.c_void_p(torch.cuda.current_stream().cuda_stream)
92      )
93      assert st == 0, f"mcblasSetStream failed: {st}"
94      st = _lib.mcblasGemmEx(
95          _handle, _MCBLAS_OP_N, _MCBLAS_OP_N,
96          N, M, K,
97          ctypes.byref(_alpha),
98          ctypes.c_void_p(b.data_ptr()), _MACA_R_16BF, N,
99          ctypes.c_void_p(a.data_ptr()), _MACA_R_16BF, K,
100         ctypes.byref(_beta),
101         ctypes.c_void_p(out.data_ptr()), _MACA_R_16BF, N,
102         _MCBLAS_COMPUTE_32F, _MCBLAS_GEMM_DEFAULT,
103     )
```

4.4 消除 prefill 每层 DtoH 同步（C500-opt10）

prefill trace 中，相邻 GPU 内核间隔大于 20 μs 的 gap 占 18.1%。主要原因之一是 vendor flash_attn 在每层每步调用 `prefill_seq_lens.tolist()`，引入 DtoH 强制同步（42 层各一次）。C500-opt10 改为在 GPU 上计算 cumsum，并将结果缓存到当前步的 `attn_metadata`，使 42 层共享一次计算。4k 与 16k 吞吐分别提升 10.9% 和 9.9%，16k TTFT 由 20.8 s 降至 18.0 s。

flash_attn.py:797--811：把每层一次的 DtoH + cumsum 改成当步缓存

```
797                 # ------------------------  Metax Modification -------------------------
798                 # For handling prefill decode split
799                 num_decode_tokens = attn_metadata.num_decode_tokens
800                 if attn_metadata.num_prefills > 0:
801                     # fl opt10: compute once per step on GPU (the old code did
802                     # tolist()->DtoH sync + HtoD + cumsum PER LAYER = 42 syncs/step)
803                     cu_prefix_kv_lens = getattr(
804                         attn_metadata, "_fl_cu_prefix_kv_lens", None
805                     )
806                     if cu_prefix_kv_lens is None:
807                         lens = attn_metadata.prefill_seq_lens
808                         cu_prefix_kv_lens = torch.cat(
809                             [lens.new_zeros(1), lens]
810                         ).cumsum(dim=0, dtype=torch.int32)
811                         attn_metadata._fl_cu_prefix_kv_lens = cu_prefix_kv_lens
```

这段代码只改变 metadata 的生产方式，不改变请求组成、调度顺序或 `vllm serve` 参数；缓存对象仍然属于当前 `attn_metadata`，不会跨请求复用旧长度。

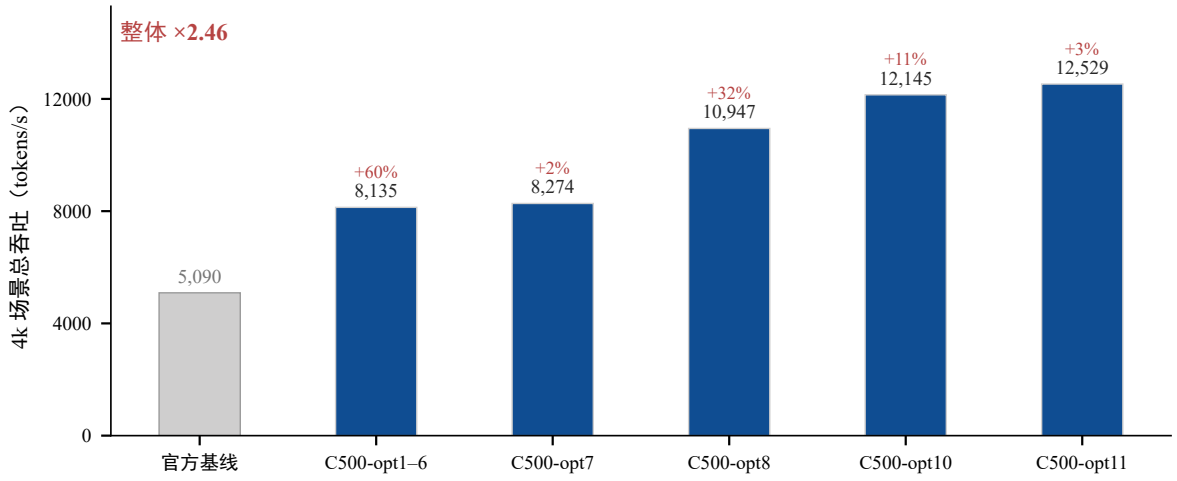


图 9 C500 4k 场景历史版本优化阶梯（含跨实例记录，非严格同机累计 A/B）

5 天数 BI-V150：vendor 接入、发射配置与自研 decode 内核

5.1 瓶颈分析

BI-V150 的瓶颈随优化阶段发生变化。初始 16k prefill 中，vLLM 通用 Triton `kernel_unified_attention` 占 GPU 忙时的 91.8%，每层每 2048-token chunk 耗时 36.8 ms；此时 GPU busy 为 99.1%，主要开销来自 attention 内核本身。iluvatar 后端缺少 flash_attn 包，是这条慢路径的直接原因。

接入 vendor attention 后，混合步的主要开销转移到 host 侧。BI-A1.5 的 16k 混合步 wall 约为 677 ms，GPU busy 为 41.3%，按此折算 GPU 工作约 280 ms、host 等待约 397 ms。builder 中两处 GPU 张量高级索引触发阻塞式 HtoD 和全流同步，每次中位耗时 78.6 ms。BI-A3 将 metadata 构建移到 CPU 侧并减少重复发射后，wall 降至 353 ms，GPU busy 提升到 76.3%。decode 侧则另有发射配置与 PV 布局转换开销，分别在后续两节展开。

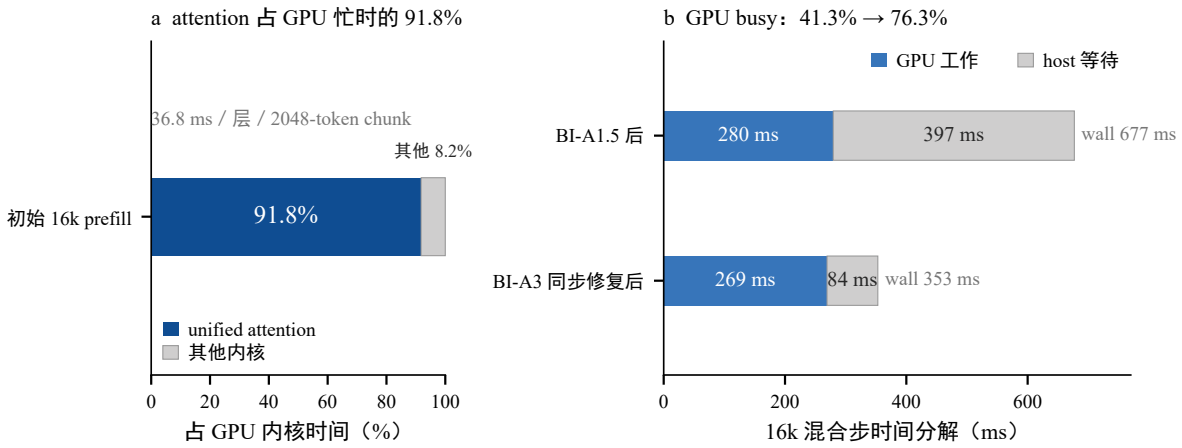


图 10 BI-V150 的 prefill 内核构成与接入 vendor 后的混合步时间分解

5.2 prefill attention 与 host 路径（BI-A1 / BI-A3 / BI-A6）

针对上述瓶颈，接入 vendor ixAttnBkd 内核，并确认其 causal 语义为 bottom-right（cmt=2），与 vLLM 的 chunk prefill 对齐。内核级实测在所有 kv 长度上均快 12–20 倍。配套地，builder 一次性完成每步 decode/prefill 划分，避免每层两次 D2H；KV 用自研 Triton `_dual_gather_kernel` 一次完成 K+V 分页收集（bit-exact，GPU 106→62 μs、host 68→37 μs），varlen 分支用 out= 直写消除 copy-out，每请求发射数由 4 降为 2。

vendor_flash_attn.py:46--57：同一 Triton program 收集一页 K 与 V

```
46      def _dual_gather_kernel(KVC, PAGES, KP, VP,
47                              E: _tl.constexpr, BLOCK: _tl.constexpr):
48          # kv_cache [blocks, 2, bs, hkv, d] flat: page p's K chunk at
49          # p*2*E, V chunk right after.  One program per page copies both.
50          pid = _tl.program_id(0).to(_tl.int64)
51          page = _tl.load(PAGES + pid)
52          offs = _tl.arange(0, BLOCK)
53          src = KVC + page * (2 * E)
54          dst = pid * E
55          for i in range(0, E, BLOCK):
56              _tl.store(KP + dst + i + offs, _tl.load(src + i + offs))
57              _tl.store(VP + dst + i + offs, _tl.load(src + E + i + offs))
```

其中 `E=bs*hkv*d` 是一页 K 的元素数，V 的源地址位于 K 之后的连续区域。内核利用这一布局在同一 program 中收集 K 和 V，数值测试与两次 `index_select` 逐位一致。

5.3 decode unified-attention 发射配置重构（BI-A7）

stock Triton 默认 `num_warps=4, num_stages=3`。扫描结果表明，该配置在 BI-V150 上并不合适，软件流水线在各 warp 档上均未带来收益。对 3D 主内核与 reduce_segments 全链路扫描后，将 3D flash-decoding 路径固定为 w1 s1，保持 TILE=16、SEG=16，2D 路径不变；输出与 stock 逐位一致。

decode_attn_pin.py:35--47：只包住 3D 内核的发射配置，2D 路径不变

```
    class _PinnedLaunch:
        def __getitem__(self, grid):
            fn = kern[grid]

            def _call(**kw):
                if kw.get("IS_3D"):
                    kw["num_warps"] = _NUM_WARPS
                    kw["num_stages"] = _NUM_STAGES
                return fn(**kw)

            return _call

    _tua.kernel_unified_attention = _PinnedLaunch()
```

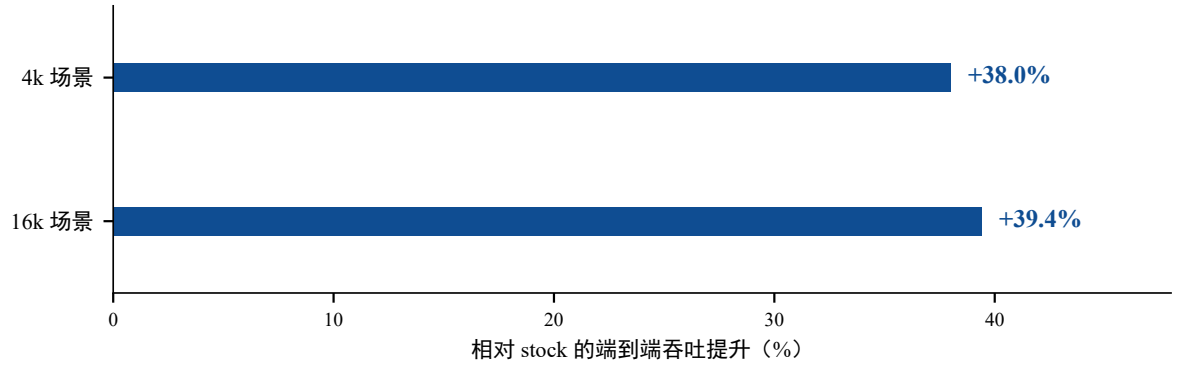


图 11 BI-A7 发射配置重构带来的端到端吞吐提升

5.4 自研 paged decode attention 内核（BI-A20）

BI-A7 之后，decode attention 仍占整步的主要时间。在同一 harness 下逐段测量 stock kernel（B=64 / kv=4096 / 16q-2kv / d=128 / block=16 / bf16）：loads+QK 的有效带宽为 509 GB/s，PV 的 `tl.dot` 耗时 0.36 ms。PV 需要将 p 从 MMA 累加器布局转换为 A 操作数布局，每个 KV block 都产生共享内存往返，因此本阶段的主要开销是布局转换。

据此重写内核（算子位于 `FlagGems/fused/paged_decode_attention.py`，插件侧为薄封装与派发）：一个 CTA = 1 warp =一个（seq, kv_head, 段），使布局转换留在 warp 内；BLOCK_N=16，p tile 不超过一个 MMA 形状；base-2 在线 softmax，scale 预折 $\log_2(e)$ 走 MUFU；主循环不加 mask，仅 ragged 尾部单独一个带 mask 的 block；段数固定、段长由 device 端 seq_lens 现算（CUDA-graph 安全），段缓存 slab 在 `apply()` 即捕获前一次性预分配；段边界按整页对齐，进一步消去逐 token 除模与向量页 gather。混合步中的 decode 行也通过 `try_fast_decode` 进入同一内核。

下面的主循环展示了三个直接针对瓶颈的选择：页边界对齐后 `page` 只需标量加载；`exp2` 代



主循环无 mask；仅 ragged 尾块 mask；段长 device 端计算，slab 在图捕获前预分配

图 12 BI-A20 paged decode attention 的分段执行与归并流程

替 `exp`；每段只写自己的 `SEG_ACC/SEG_MAX/SEG_SUM`，最后由 combine 按 $\exp 2(m_i - m)$ 加权归并。

`paged_decode_attention.py:169--193`：页对齐主循环与 base-2 在线 softmax

```
169     for t0 in range(start, end, BS):
170         page = tl.load(BT + pid_s * stride_btb + (t0 // BS) * stride_btp)
171         if t0 + BS <= kvlen:
172             kt = tl.load(K + page * stride_kb + pos[None, :] * stride_ks
173                          + pid_h * stride_kh + offs_d[:, None] * stride_kd)
174             vt = tl.load(V + page * stride_vb + pos[:, None] * stride_vs
175                          + pid_h * stride_vh + offs_d[None, :] * stride_vd)
176             s = tl.dot(qv, kt) * scale
177         else:
178             mask_t = t0 + pos < kvlen
179             kt = tl.load(K + page * stride_kb + pos[None, :] * stride_ks
180                          + pid_h * stride_kh + offs_d[:, None] * stride_kd,
181                          mask=mask_t[None, :], other=0.0)
182             vt = tl.load(V + page * stride_vb + pos[:, None] * stride_vs
183                          + pid_h * stride_vh + offs_d[None, :] * stride_vd,
184                          mask=mask_t[:, None], other=0.0)
185             s = tl.where(mask_t[None, :], tl.dot(qv, kt) * scale,
186                          float("-inf"))
187         m_new = tl.maximum(m_i, tl.max(s, 1))
188         alpha = tl.exp2(m_i - m_new)
189         p = tl.exp2(s - m_new[:, None])
190         l_i = l_i * alpha + tl.sum(p, 1)
191         acc = acc * alpha[:, None] + tl.dot(p.to(vt.dtype), vt)
192         m_i = m_new
193
```

paged_decode_attention.py:207--223：分段结果的在线归并

```
207     pid_s = tl.program_id(0)
208     pid_h = tl.program_id(1)
209     offs_g = tl.arange(0, GQA)
210     offs_d = tl.arange(0, D)
211     offs_n = tl.arange(0, NSEG)
212
213     base = (pid_s * HKV + pid_h) * NSEG
214     mx = tl.load(SEG_MAX + (base + offs_n)[None, :] * GQA + offs_g[:, None])
215     sm = tl.load(SEG_SUM + (base + offs_n)[None, :] * GQA + offs_g[:, None])
216     m = tl.max(mx, 1)
217     w = tl.exp2(mx - m[:, None])
218     denom = tl.sum(w * sm, 1)
219     accs = tl.load(SEG_ACC + ((base + offs_n)[None, :, None] * GQA + offs_g[:, None, None]) * D
220                    + offs_d[None, None, :])
221     out = tl.sum(accs * w[:, :, None], 1) / denom[:, None]
222     tl.store(OUT + pid_s * stride_ob + (pid_h * GQA + offs_g)[:, None] * stride_oh
223              + offs_d[None, :] * stride_od, out.to(OUT.dtype.element_ty))
```

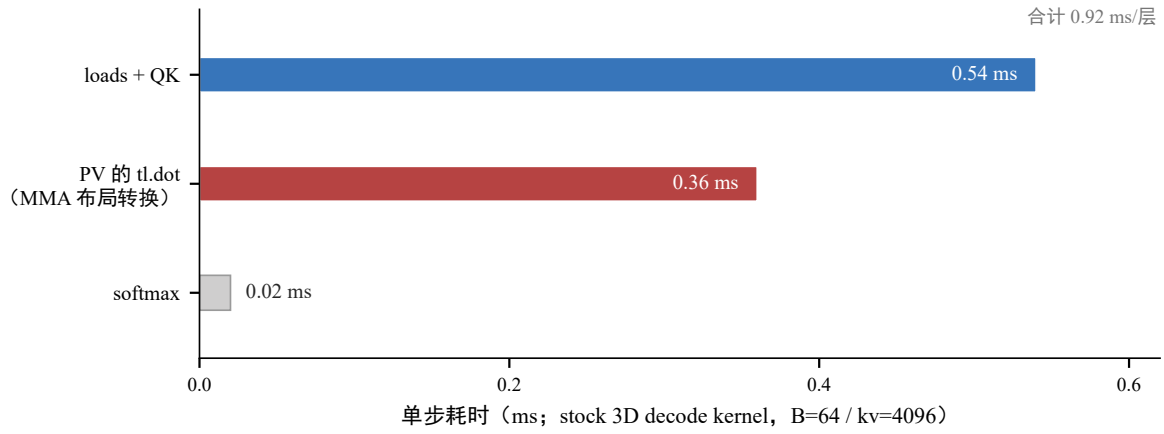


图 13 stock 3D decode 内核的耗时分解：瓶颈在 PV 的 MMA 布局转换

BI-A20 阶段的页对齐微基准中，stock 为 0.939 ms/层、286 GB/s，BI-A20 为 0.588 ms/层、457 GB/s，加速比 1.60×；等长与 ragged 的最大误差分别为 3.05×10^{-5} 和 6.10×10^{-5}。两组官方 A/B 的 4k 结果为：BI-A7 3855.31→BI-A20 4087.91（+6.0%），BI-A7 3840.80→BI-A20 4722.22（+22.9%）；16k 结果为：BI-A7 3568.31→BI-A20 4520.19（+26.7%），BI-A7 3570.61→BI-A20 4520.10（+26.6%）。两组 16k TTFT 分别为 111.64 s 和 111.67 s，较 BI-A7 降低 18.5% 和 18.4%。该阶段两次 MATH-500 Level 3 为 96.19% 和 98.1%。

5.5 批量一致性与路径检查

每个（seq, kv_head, segment）只依赖自身的 q、KV 页和 seq_lens，段长仅由序列长度决定。交付中的 `tests/test_paged_decode_attention.py` 包含 8 个 fp32 参考对照用例和一个

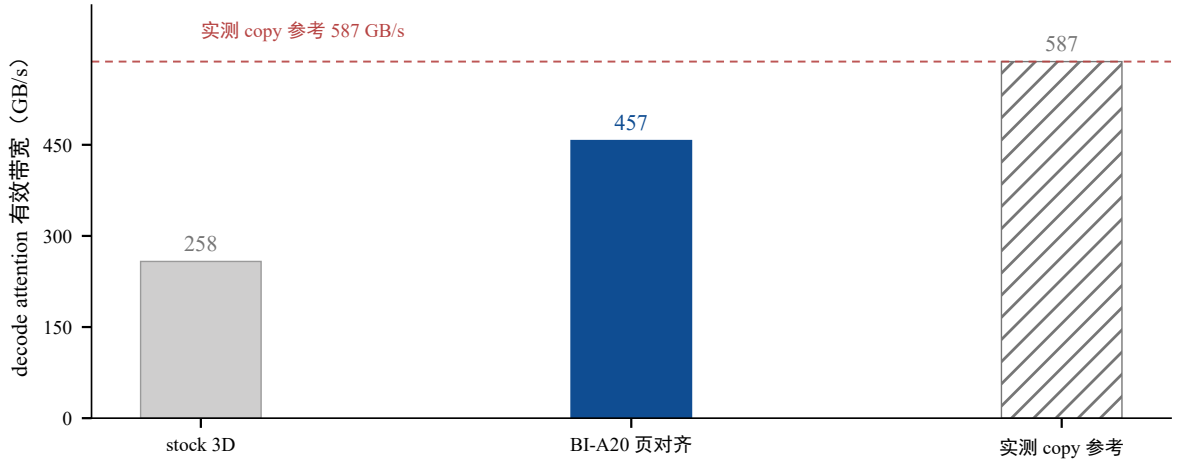


图 14　stock 与页对齐版本的 decode attention 有效带宽对比（kv=4096，B=64）

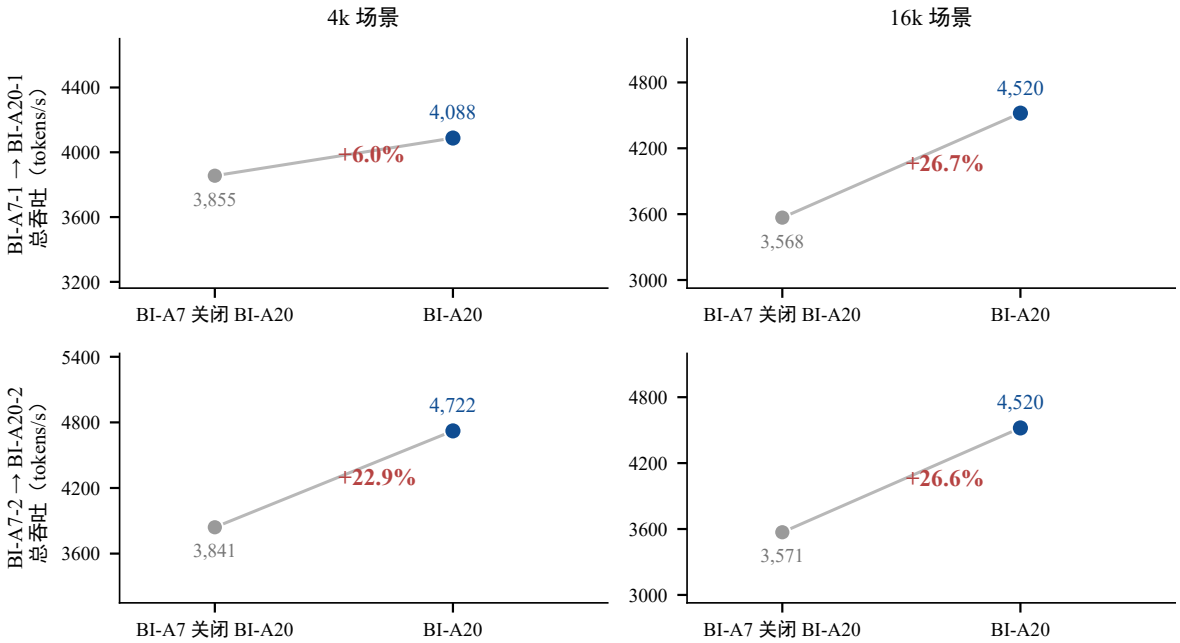


图 15　BI-V150 两组官方 A/B：BI-A7 栈关闭 BI-A20 与当前 BI-A20 的对比

批量不变性用例，在 BI-V150 上实测 **9 passed**。批量测试覆盖单条、两条、半批、全批和逆序全批，并重复执行同一批组成。混合步的 decode 切片每 4000 次调用记录 used/skipped；当前日志为 used=132000、skipped=0。

decode_attn_fast.py:186--205：混合步 decode 切片的资格检查、计数与异常回退

```
186 def try_fast_decode(impl, query, kv_cache, md, out):
187     """Entry point for the mixed-step (prefill+decode) path.
188 
189     Returns True when the fast kernel computed `out` for the decode slice.
190     A periodic INFO line reports the engagement ratio so a run can be
191     audited from its serve log alone.
192     """
193     if _DISABLED or md is None:
194         return False
195     if not _eligible(impl, query, kv_cache, md, None):
196         _slice["skip"] += 1
197         _slice_report()
198         return False
199     _slice["used"] += 1
200     _slice_report()
201     try:
202         return _fast_forward(impl, query, kv_cache, md, out) is not None
203     except Exception as exc:
204         logger.warning("decode_attn_fast: slice fallback (%s)", exc)
205         return False
```

满足形状与特征条件时进入新内核；遇到不支持的特征或异常则回到原实现。used 在内核执行前递增，表示通过资格检查并尝试 fast path；本次同时检查了 fallback 日志，未出现 decode fast-path 异常回退。

5.6 配置缓存与单表反射（BI-A31）

设备 trace 显示，部分反复间隙出现在 `_index_linearized_jit_function` 之前。进一步对 `ModelRunnerFL.execute_model` 做 cProfile，发现这些间隙主要来自算子配置读取和 SQLAlchemy 模型反射，而不是 index kernel 本身：原版 `get_config` 累计约 65.14s，全库 reflection 约 53.76s。该问题属于执行线程中的配置与元数据开销，不能通过单纯加快 attention kernel 解决。

BI-A31 在 `utils/libentry.py` 中为同一 shape 的配置和缺失结果增加进程内缓存，`set()` 同步更新；`FLAGGEMS_CONFIG_CACHE_LOCAL=0` 可恢复直接数据库读取。在 `utils/models/sql.py` 中，将新模型的全库 automap reflection 改为只加载目标表；配置表不存在时仍返回 `None` 并进入 autotune，保持原回退语义。真实配置库的单表加载由 4212.64 ms 降至 26.35 ms，候选版 `_index_linearized` 累计时间由 66.03s 降至 4.47s。配置缓存与缺失表两项针对性测试均通过。

BI-A31 的 MATH-500 Level 3 为 98.1%，105/105 请求成功、0 错误。4k 的提升来自减少

表 5 BI-A31 官方四轮去首均值与同日交错对照

场景	对照	总吞吐（tok/s）	TTFT（ms）	变化
4k A1/A2	BI-A20	4667.18 / 4459.34	4196.06 / 4265.06	—
4k B2/B1	BI-A31	5209.16 / 5208.95	4043.57 / 4025.01	+14.15%
4k 中位数	BI-A20 → BI-A31	4563.26 → 5209.06	4230.56 → 4034.29	吞吐 +14.15%；TTFT −4.64%
16k 中位数	BI-A20 → BI-A31	4513.93 → 4513.91	111831.96 → 111817.66	基本持平

配置和 host 开销。16k 的原版配置获取仍累计约 48.47s，但 BI-A31 后总 host 时间仅从 148.42s 降至 141.48s，attention metadata、copy 与设备计算成为主要部分，因此官方吞吐基本持平，不把 4k 收益外推到 16k。原始证据见 `docs/experiments/runs/a31-config-local-cache/`。

5.7 双累加器门控融合与 K 连续权重预打包（BI-A48 / BI-A60）

BI-A48 使用两个独立的 FP32 累加器分别计算 gate/up，共享 A tile 加载，并直接写出 $gate \cdot \mathrm{sigmoid}(gate) \cdot up$，避免中间激活的额外读写。官方 4k 两组中位数由 5201.98 增至 5237.32 tok/s（+0.679%），16k 由 4524.55 增至 4556.53 tok/s（+0.707%），两种场景的 TTFT 均改善，MATH-500 Level 3 为 98.1%。

BI-A60 保留上述数值路径，仅改变 B 矩阵的物理布局。设 $BK = 32$、$BN = 128$，gate/up 分别重排为 $[K/BK, N/BN, BN, BK]$，即同一 tile 内的 K 维连续。内核以 $[BK, BN]$ 逻辑形状执行 `tl.dot`，写回时使用全局 `rn` 偏移；K、N 可整除时进入该路径，否则回退 A48。预打包结果按权重地址、设备、dtype、形状和 stride 缓存，缓存项保留原权重引用，稳态 decode 不重复转换。

mm_silu_mul.py:99--113：K 连续 tile 打包与单次缓存

```
99  def _tile_pack_slice(x):
100     k, n = x.shape
101     return x.contiguous().view(k // 32, 32, n // 128, 128).permute(
102         0, 2, 3, 1
103     ).contiguous()
104
105
106 def _tile_packed_weights(b):
107     key = (b.data_ptr(), b.device, b.dtype, b.shape, b.stride())
108     if key not in _TILE_PACKED:
109         n = b.shape[1] // 2
110         gate = _tile_pack_slice(b[:, :n])
111         up = _tile_pack_slice(b[:, n:])
112         _TILE_PACKED[key] = (b, gate, up)
113     return _TILE_PACKED[key][1:]
```

修正后的微基准仅用于候选筛选：decode 约快 10%，prefill 约快 3.85%。早期探针中的多余转置和局部 N 偏移写回错误均已排除，不采用其计时。实现通过官方形状与缓存测试（3 passed）。

在公开 tag 的 `a7620cc1` 基线上，两组官方交错 A/B 结果为：

表 6 BI-A60 开发期官方结果（公开 tag 基线，两组中位数）

场景	A48（tok/s）	A60（tok/s）	吞吐变化	TTFT：A48 → A60（ms）
4k	5238.28	**5314.15**	+1.448%	3915.97 → 3835.52（−2.06%）
16k	4551.39	**4620.25**	+1.513%	110380.58 → 118779.35（+7.63%）

该轮 MATH-500 Level 3 为 96.19%，16k TTFT 相比 A48 对照增加 7.63%，但仍远低于官网基线及其 +1% 上限。这里同时保留吞吐收益和延迟差异，不把历史同日 A/B 的 TTFT 当作官网约束的唯一判据。

官方镜像确认后，完整 A20+A31+A48+A60 栈已重放到 FlagGems `4df52d91`，性能测量提交为 `85b4ba82`；最终集成分支 `ef516137` 只追加换行规范化。4k 三次独立四轮测量为 5131.78 / 5292.46 / 5292.99 tok/s，中位数 **5292.46 tok/s**，TTFT 3908.25ms；16k 四轮汇总为 **4618.41 tok/s**，TTFT 118761.15ms。最终 MATH-500 Level 3 为 **98.1%**，105/105 成功、0 错误。原始 CSV、日志、测试与精度报告见 `docs/experiments/runs/a60-tile-packed/` 和 `docs/experiments/runs/image-baseline-align/`。

6 跨平台结果与组合消融

6.1 组合有效性与消融分析

采用论文常用的 *full-model-minus-one* 形式：以完整交付栈为 Full，逐项移除组件，Δ 均为“变体减 Full”，负值表示性能下降。BI-V150 的变体来自同日交错 A/B；C500 每个变体执行一次完整四轮 benchmark，属于组合诊断，不代替新候选正式 A/B/A/B。

表 7 C500 消融：完整模型与逐项移除组件（4k）

模型变体	总吞吐（tok/s）	Δ（tok/s）	Δ	TTFT（ms）
Full（全部优化）	**12527.62**	0.00	0.00%	1623.73
w/o 采样融合	11785.47	−742.15	−5.92%	1644.35
w/o prefill mcBLAS	9371.69	−3155.93	−25.19%	2072.08
w/o lm_head nn	12458.35	−69.27	−0.55%	1635.81
w/o mcBLAS 与采样融合	8946.83	−3580.79	−28.58%	2093.73

采样融合与 prefill mcBLAS 的移除均造成可见损失，其中后者是 4k 组合中最大的单项贡献。lm_head nn 的边际影响较小，但保留该路径不涉及额外运行参数或模型语义变化。双组件移除用于检验交互：独立乘法模型预期为 $11785.47 \times 9371.69/12527.62 = 8816.50$ tok/s，实测 8946.83 tok/s，较预期高 1.48%，未发现两条主要路径组合后相互回退。C500 同机 16k Full 复核为 11143.77 tok/s、TTFT 17961.76 ms。

移除 BI-A20 后，两组 16k 吞吐均下降约 21%，说明页对齐 decode 内核是长上下文组合的关键组件；移除 BI-A31 后，4k 下降 12.40%，而 16k 基本持平，表明配置与 host 优化

表 8 BI-V150 消融：Full 与移除 BI-A20 / BI-A31 的同日交错对照

消融对照	场景	Full（tok/s）	移除后（tok/s）	Δ
BI-A20，第 1 组	4k	4087.91	3855.31	−5.69%
BI-A20，第 2 组	4k	4722.22	3840.80	−18.67%
BI-A20，第 1 组	16k	4520.19	3568.31	−21.06%
BI-A20，第 2 组	16k	4520.10	3570.61	−21.01%
BI-A31，两组中位数	4k	5209.06	4563.26	−12.40%
BI-A31，两组中位数	16k	4513.91	4513.93	≈ 0.00%

具有场景依赖性。两组 BI-A20 结果均保留，不以单组高值代替整体波动。原始数据见 `docs/experiments/runs/bi-final-audit/`、`docs/experiments/runs/a31-config-local-cache/` 和 `docs/experiments/runs/c500-next-optimization/c500-combination-ablation.md`。

后续候选 BI-A36 将全页主循环与唯一尾页分离。该改动在同机微基准中使 4k 等长与 ragged 内核分别加速 1.0838 倍和 1.1164 倍，16k 分别加速 1.1470 倍和 1.1430 倍，但完整模型呈显著回退。修复后同日交错对照的基线 A1/A2 为 5114.00/5164.83 tok/s，候选 B1/B2 为 4497.70/4500.68 tok/s，中位数由 5139.42 降至 4499.19（−12.46%）。因此 BI-A36 不合入：孤立内核加速不能替代完整模型的组合验证。修复窗口前后的数据单独标记，不参与该结论。

BI-A50/A51 的厂商 paged prefill 接口分别受当前镜像执行错误和 KV stride 约束阻塞，未取得有效性能数据；BI-A52/A53 的 NSEG 扫描在官方等长 4k 上最佳仅约 1.5% 孤立收益，且 16k 回退，不纳入最终模型。BI-A54 复核 A45 与 A48 的组合，4k 中位数变化 −0.4745%、16k 仅 +0.0308%，两场景平均吞吐变化 −0.2397%；BI-A55 复核 A46/A47 与 A48 的组合，16k 变化 −0.478%，两者均不合入。BI-A56 的真实 Inductor 图审计确认 RoPE、residual+RMSNorm 与 A48 前置链均已融合，未发现新的原生融合候选。第二轮 host/ixsys 复核中，BI-A57 将 FlagGems 默认日志改为 INFO，官方 4k 中位数变化 −0.2394%；BI-A58 的 decode warps=16 在微基准快 3.64%，但官方两组中位数变化 −0.0336%，均未合入。相关原始记录位于 `docs/experiments/runs/`。

6.2 跨平台结果对照

图 16 对比两种芯片的历史收益构成。C500 的 C500-opt1–opt6 包含跨实例版本记录，展示开发过程而非严格同机累计 A/B；BI-V150 的 BI-A6、BI-A7、BI-A20 使用各自的当日对照，三组数据不作累计。

局部加速与端到端收益的关系见图 17。其中 C500-opt8 的横坐标为四种 prefill GEMM 形状加速比的算术平均值，BI-A20 为 stock 0.939 ms 与页对齐版本 0.588 ms 之比。由于各内核在完整模型中的时间占比不同，局部加速比与端到端提升之间不存在固定的线性换算关系。

图 18 进一步比较内核效率。左图将 decode attention 带宽分别归一到同芯片的实测参考：BI-V150 使用 copy 587 GB/s，C500 使用 sum 1610 GB/s；两种参考不作为跨芯片的绝对性能排名。右图给出 C500 四种 prefill GEMM 形状的计算吞吐，Triton 数值由相同矩阵运算量与实测耗时计算。

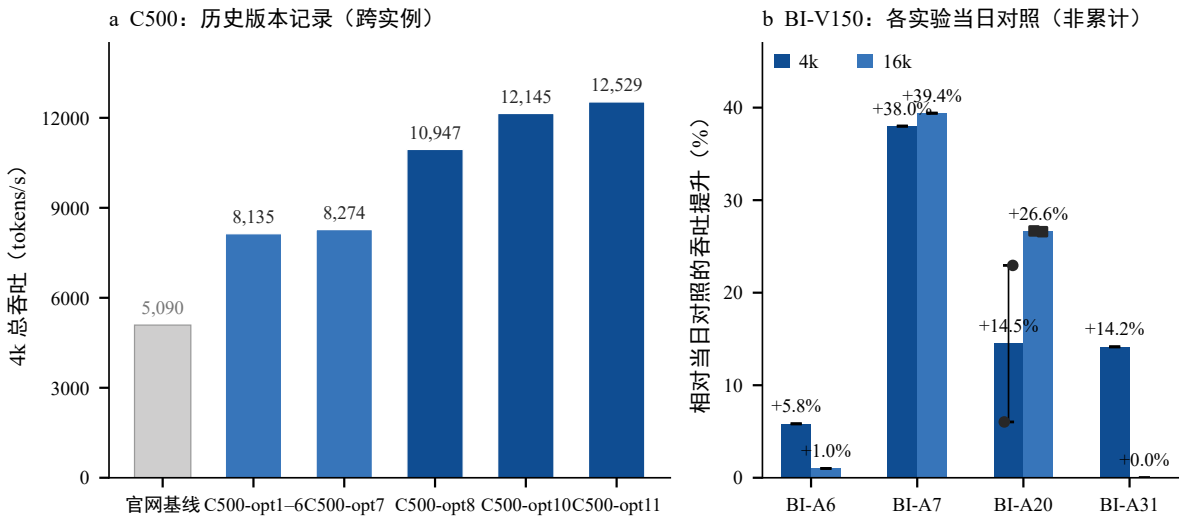


图 16　优化阶段的吞吐收益：C500 为跨实例历史版本记录，BI-V150 为各实验的当日对照

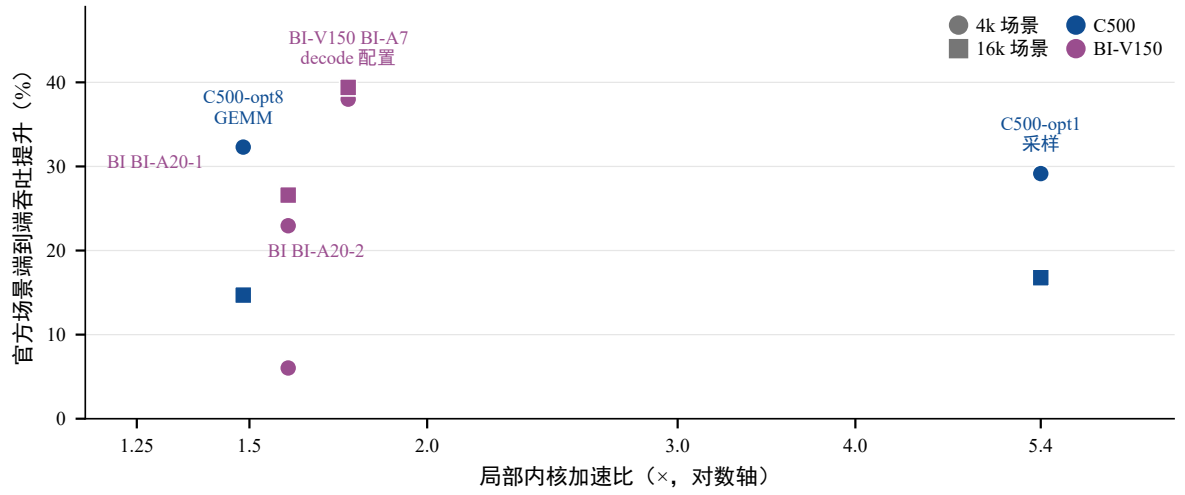


图 17　局部内核加速比与官方场景端到端吞吐提升的关系

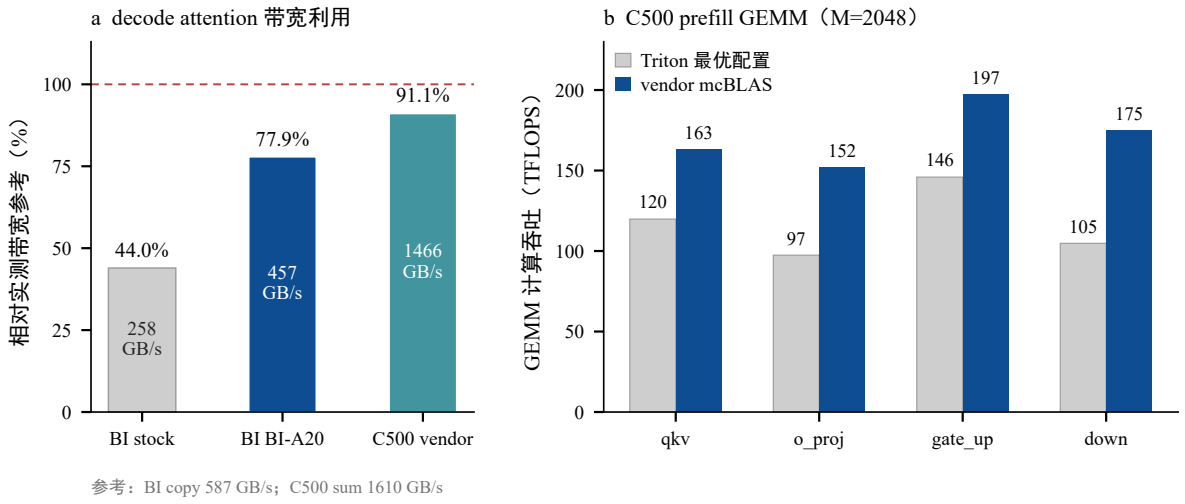


图 18　decode attention 带宽利用与 C500 prefill GEMM 计算吞吐

7 正确性验证

正确性检查覆盖内核数值、批量不变性、采样分布和端到端精度。各层的测试对象、开发记录与当前状态见下表。

表 9 正确性验证矩阵：从单个 kernel 到完整服务

验证层	对象与方法	开发记录与状态
bit-exact	BI-A6 双 gather、BI-A7 发射配置	BI-A6 与两次 `index_select` 逐位一致；BI-A7 与 stock 的 `max_diff`=0.0
数值误差	BI-A20 vs stock，含 ragged 形状	等长最大 3.05×10^{-5}，ragged 最大 6.10×10^{-5}
批量不变性	单条 / 两条 / 半批 / 全批 / 逆序全批，对照 fp32	BI-V150 实测 9 passed
采样等价	greedy、top-p、Gumbel 与 TV 距离	greedy 与 `torch.argmax` 完全一致；保留集 IoU ≥ 0.999；TV 与参考实现同档
权重布局	BI-A60 官方形状与缓存内容	BI-V150 实测 3 passed；非法 tile 形状回退 A48
端到端精度	evalscope MATH-500 Level 3（105 题）	C500 两次均为 98.1%；BI 最终栈为 98.1%，105/105 成功、0 错误
真实路径命中	混合步 decode 切片 used/skipped	当前日志 used=132000、skipped=0，未见 decode fast-path 异常回退
启动验证	固定交付源码路径 + 独立 venv + 官方启动	C500 实测版本完成官方四轮 benchmark 与两次精度评测；启动耗时随 autotune 缓存约 127–1129 秒，原生基线 161 秒

8 合规对照与复现指南

8.1 合规对照

表 10 赛题约束与本提交做法

约束	本提交做法
`vllm serve` 参数与基线一致	两张卡均按官网原命令启动，未增删任何参数；C500 不额外添加 `--compilation-config`
禁止 benchmark 脚本调优	未修改官方脚本；当前 C500 与历史 C500-opt 采用四轮去首后三轮均值，其他单次测量单独标明
禁止直接 merge 上游分支	基线为 flagos-2026-s2 与天数镜像 FlagGems `4df52d91`；我们的提交在该镜像基线上重放，不以公开 tag 的后续提交替代
算子优化须有开发量	新增 Triton 内核（paged decode attention、采样链、dual-gather）与路由/同步改造，均可独立 A/B
禁止改超参开启量化、投机采样	保持官方模型精度与生成配置，不启用量化或投机采样
精度 ≥ 0.95	C500 两次均为 98.1%；BI 最终栈为 98.1%，105/105 成功、0 错误
TTFT 上限为官网 baseline +1%	两平台各场景均满足：BI 最终 4k 为 3.91s，低于官网 11.57s；16k 为 118.76s，低于官网 599.26s

8.2 复现步骤

先取得两个集成分支（保留完整历史），再分别以可编辑模式安装：

源码获取与安装

```
git clone --single-branch --branch integration/vllm-plugin-fl \
  https://github.com/xy200303/vllm-plugin-FL.git vllm-plugin-FL
git clone --single-branch --branch integration/flaggems \
  https://github.com/xy200303/FlagGems.git FlagGems

cd vllm-plugin-FL && pip install -e . --no-build-isolation
cd ../FlagGems   && pip install -e . --no-build-isolation
```

两平台均设置 `VLLM_PLUGINS=fl`。C500 还需以下环境变量；当镜像已有其他版本的插件时，同时固定源码路径，避免加载到非交付目录：

C500 环境变量

```
export PATH=/opt/conda/bin:$PATH
export MACA_PATH=/opt/maca
export MACA_HOME=/opt/maca
export LD_LIBRARY_PATH=/opt/maca/lib:/opt/maca/lib64
export VLLM_PLUGINS=fl
export PYTHONPATH=/workspace/vllm-plugin-FL:/workspace/FlagGems/src
```

启动命令与官网完全一致，天数在官方命令后追加编译配置，C500 不追加：

官方启动命令（与基线一致）

```
# 天数 BI-V150
vllm serve /workspace/MiniCPM5-2B --port 9031 --served-model-name minicpm \
  --gpu-memory-utilization 0.85 --max-model-len 131072 \
  --compilation-config '{"cudagraph_mode": "FULL_DECODE_ONLY"}'

# 沐曦 C500（不添加 --compilation-config）
vllm serve /workspace/MiniCPM5-2B --port 9031 --served-model-name minicpm \
  --gpu-memory-utilization 0.85 --max-model-len 131072
```

性能评测执行官方脚本并传入两个官方用例：

官方性能评测命令

```
python3 vllm-plugin-FL/benchmarks/benchmark_throughput_serve.py \
  --model /workspace/MiniCPM5-2B --served-model-name minicpm --port 9031 \
  --test-cases '[[4096,1024,64,256],[16384,1024,64,128]]'
```

精度评测执行官网给出的 evalscope 命令。结果位于工作目录的 `<timestamp>/reports/minicpm/math_500.json`；当前 evalscope 版本的精度字段为 `metrics[0].score`。

8.3 复现注意事项

（1）检查 prefix cache：benchmark 使用 seed=0，同一 serve 上重复相同 input_len 的负载可能命中 prefix cache；本队日志出现过 35.9% 命中率，并伴随 prefill 开销降低和吞吐虚高。旧日志不能证明各次运行均无命中，因此每个数据点都须检查命中率日志，必要时在新启动的 serve 上测量。各次最终复测的命中率低于 1%。

（2）C500 需要 ≥128 GB CPU 内存：在模力方舟 64 GB 内存规格实例上，纯镜像原版 `vllm serve` 也会在 inductor 编译阶段被 cgroup OOM killer 杀掉（匿名内存峰值 63.4 GB，被杀时 GPU 显存仅 858 MiB，与显存、负载、代码改动均无关）。128 GB 规格实例全程稳定。

（3）启动耗时：C500 需执行 GEMM autotune 预热。实测记录约 127–1129 秒，原生基线为 161 秒；预热时间随实例和缓存状态变化，不能用固定秒数估计。

（4）测量波动：C500 实测版本 4k 后三轮吞吐极差为 0.80%，16k 为 0.29%。BI 最终版本的三次 4k 独立四轮测量为 5131.78 / 5292.46 / 5292.99 tok/s，首测受设备冷态影响，报告采用中位数并保留全部三次结果；16k 单次四轮测量为 4618.41 tok/s，与旧实例基本一致。C500 同时保留官网与本机原生基线，避免跨实例参照混淆。

9 结论

本文在官方 FlagOS 栈上完成了 MiniCPM5-2B 的双平台推理优化。C500 的主要收益来自采样链融合、GEMM 路由和 prefill 同步消除；BI-V150 的主要收益来自 vendor attention 接入、发射配置调整、paged decode attention 重写、配置/host 开销消除、门控融合和 K 连续权重预打包。C500 已完成的复测中，4k 与 16k 吞吐分别为官网基线的 2.46 倍和 1.59 倍，为本机原生基线的 2.98 倍和 1.90 倍。BI 最终栈在官方镜像基线重放后，4k 三次独立四轮测量中位数为 5292.46 tok/s，16k 为 4618.41 tok/s，分别为官网基线的 2.61 倍和 5.05 倍。C500 两次 MATH-500 均为 98.1%，BI 最终栈为 98.1%，均满足赛题要求。

C500 已完成复测的 4k TTFT 为 1623.73 ms，16k TTFT 为 17961.76 ms，均优于官网和本机原生基线；BI 最终栈的 4k TTFT 为 3908.25 ms，16k 为 118.76 s，均满足官网 TTFT 上限。BI 的首次 4k 测量为 5131.78 tok/s，随后两次稳定在 5292 tok/s 以上，报告保留该波动。后续可继续研究 prefill 分块策略和编译器融合，并在更多国产芯片上检验这些实现的适用性。

参考文献

[1] 中华人民共和国国家质量监督检验检疫总局, 中国国家标准化管理委员会. GB/T 7713.3-2014 科技报告编写规则 [S]. 北京: 中国标准出版社, 2014.

[2] KWON W, LI Z, ZHUANG S, et al. Efficient memory management for large language model serving with PagedAttention[C]//Proceedings of the 29th ACM Symposium on Operating Systems Principles (SOSP). 2023: 611-626.

[3] DAO T, FU D Y, ERMON S, et al. FlashAttention: fast and memory-efficient exact attention with IO-awareness[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022.

[4] MADDISON C J, MNIH A, TEH Y W. The concrete distribution: a continuous relaxation of discrete random variables[C]//International Conference on Learning Representations (ICLR). 2017.

[5] FlagOS Community. vllm-plugin-FL, branch flagos-2026-s2[EB/OL]. https://github.com/flagos-ai/vllm-plugin-FL.

[6] FlagOS Community. FlagGems, tag v5.3.5[EB/OL]. https://github.com/flagos-ai/FlagGems.

[7] OpenBMB. MiniCPM5-2B[EB/OL]. https://modelscope.cn/models/OpenBMB/MiniCPM5-2B.

A 代码与实验记录索引

代码分支：插件为 `xy200303/vllm-plugin-FL` 的 `integration/vllm-plugin-fl`（至 b5793cd4）；算子为 `xy200303/FlagGems` 的 `integration/flaggems`（至 ef516137，基于官方镜像 FlagGems `4df52d91`）。两者均在性能测量提交之后只追加了换行规范化。公开 tag 旧集成分支持久化为 tag `archive/flaggems-public-tag`，其他历史开发线归档于 `archive/*`。报告与实验记录另存于 `xy200303/minicpm-flagserve` 的 `main`。

实验记录：`docs/baselines/metax-c500/`（C500 基线与 C500-opt1–opt11 逐项记录）、`docs/baselines/iluvatar-biv150/`（天数 BI-A1–A9 记录）、`docs/experiments/`（后续实验、台账 `tracking.md` 与 `runs/` 原始数据）。目录中包含配置、serve 日志、benchmark CSV 和机器状态。

A.1 结果与原始证据对应表

以下路径均相对于文档仓库 xy200303/minicpm-flagserve 的根目录。汇总 CSV 可由同目录原始 CSV 复算，精度取 JSON 的 `metrics[0].score`；日志同时保留启动参数、实际加载路径和逐轮运行过程。

表 11　关键代码文件与报告章节的对应关系

文件（相对各自源码根目录）	作用与对应章节
`vllm_fl/dispatch/backends/vendor/metax/patches/sampler_tail_fusion.py`	C500 采样链接入，§4.2
`vllm_fl/dispatch/backends/vendor/metax/patches/linear_nn_repack.py`	nn 权重复本与形状路由，§4.3
`vllm_fl/dispatch/backends/vendor/metax/patches/mcblas_mm.py`	ctypes 直调 vendor mcBLAS，§4.3
`vllm_fl/dispatch/backends/vendor/metax/impl/attention/flash_attn.py`	prefill metadata 的当步 cumsum 缓存，§4.4
`vllm_fl/dispatch/backends/vendor/iluvatar/impl/vendor_flash_attn.py`	vendor prefill、混合步拆分、双 gather，§5.2
`vllm_fl/dispatch/backends/vendor/iluvatar/impl/decode_attn_pin.py`	3D decode 发射配置，§5.3
`vllm_fl/dispatch/backends/vendor/iluvatar/impl/decode_attn_fast.py`	BI-A20 资格检查、slab、混合步回退，§5.4–5.5
`src/flag_gems/fused/top_p_sample.py`	直方图 top-p 与 Gumbel-Max，§4.2
`src/flag_gems/fused/paged_decode_attention.py`	BI-A20 分段内核与 combine，§5.4
`src/flag_gems/runtime/backend/_iluvatar/fused/mm_silu_mul.py`	BI-A48 门控融合与 BI-A60 tile 预打包，§5.7
`vllm_fl/dispatch/backends/vendor/iluvatar/impl/mm_silu_mul.py`	BI-A48 MLP 路由与回退，§5.7
`src/flag_gems/utils/libentry.py`	BI-A31 配置查询与缺失结果进程内缓存，§5.6
`src/flag_gems/utils/models/sql.py`	BI-A31 目标表加载与缺失回退，§5.6
`tests/test_paged_decode_attention.py`	精度与批量不变性测试，§5.5、§6

表 12 报告结果、代码版本与原始证据索引

结果	代码 / 对照	原始证据（路径与文件）
C500 实测性能	插件 0207b7e1；算子 9c06143c	docs/experiments/runs/c500-next-optimization/c500-current-4k-a1/summary.csv、c500-current-16k-a1/summary.csv 及各自原始 CSV / serve / bench 日志
C500 原生基线	插件 13eb9be；FlagGems v5.3.5	docs/experiments/runs/c500-final-audit/healthy-baseline-raw.csv、healthy-baseline-summary.csv、healthy-baseline-serve.log
C500 精度与微基准	插件 0207b7e1；算子 aff68555	docs/experiments/runs/c500-final-audit/healthy-eval1-math500.json、healthy-eval2-math500.json、micro-healthy.json；环境见 healthy-final-manifest.txt
BI-V150 两组 A/B	BI-A7 对照与 BI-A20；同一交付提交内开关切换	docs/experiments/runs/bi-final-audit/1-a7/benchmark_results/、1-a20/、2-a7/、2-a20/ 下的 benchmark_results/；同级 serve / bench 日志
BI-V150 精度	BI-A20 实测提交	同目录 eval1-math500.json、eval2-math500.json、eval-serve.log
BI-V150 内核验证	BI-A20 与 stock	同目录 micro.json、pytest-a20.log、manifest.txt；测试脚本为 docs/verification/bi_micro_audit.py
BI-A31	BI-A20 与 BI-A31（cf11897a）	docs/experiments/runs/a31-config-local-cache/：a31-official-evidence.tar.gz、a31-16k-evidence.tar.gz、a31-eval.tar.gz、host.prof
BI-A48	插件 58bae94；FlagGems 3642366c	docs/experiments/runs/a48-dual-acc-silu-mul/：official-4k-v4/summary.json、official-16k/summary.json、eval/eval1-math500.json 及各次原始 CSV / 日志
BI-A60	实验 ffe47a67；公开 tag 集成 e9390c54	docs/experiments/runs/a60-tile-packed/：official-4k-summary.json、official-16k-summary.json、gems-tests-v5.log、eval/eval1-math500.json 及各次原始 CSV / 日志
BI 镜像对齐最终复测	FlagGems 测量 85b4ba82、最终 ef516137；插件测量 58bae94、最终 b5793cd4；基线 4df52d91	docs/experiments/runs/image-baseline-align/：bench-evidence.tar.gz、eval-evidence.tar.gz、tests.tar.gz、manifest.txt

A.2 官网基线来源

官网基线位于赛题页面“4.3 评审方案”的“天数基线”和“沐曦基线”图片中，访问日期为2026-11-11：https://flagos.io/race-detail-season2?id=539vlt2p&lang=cn。原图随报告源文件保存为 `official_baseline_biv150.png` 与 `official_baseline_c500.png`；图 19 原样展示，报告表 3 的官网基线数字由这两张表读取。

Prefill	Decode	Conc	Num Prompts	Benchmark Duration (s)	Output tok/s	Total tok/s	Mean TTFT (ms)
4096	1024	64	256	646.31	405.6	2028.01	11573.53
16384	1024	64	128	2434.82	53.83	915.15	599262.03

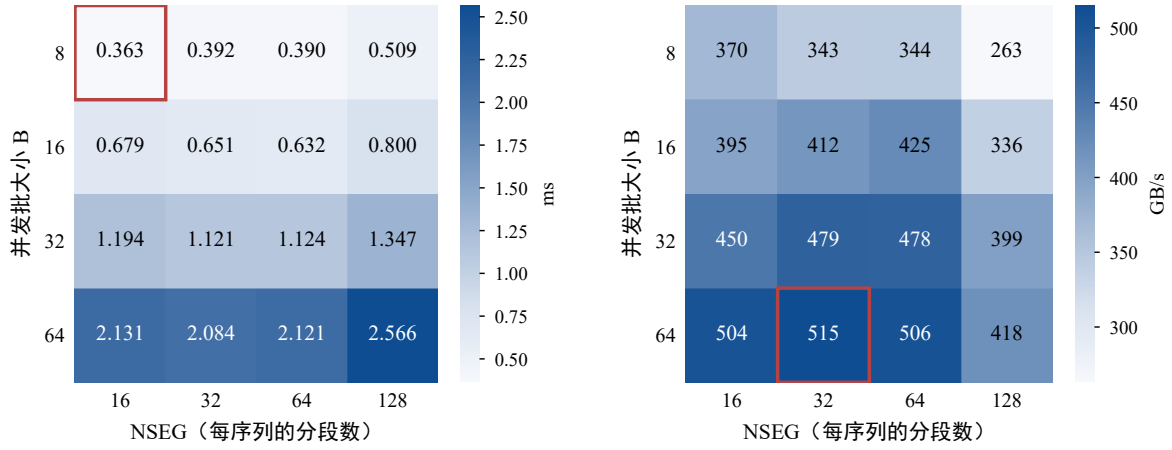
Prefill	Decode	Conc	Num Prompts	Benchmark Duration (s)	Output tok/s	Total tok/s	Mean TTFT (ms)
4096	1024	64	256	257.525	1017.93	5089.645	3199.435
16384	1024	64	128	316.975	413.51	7029.675	27197.135

图 19 官网天数 BI-V150（上）与沐曦 C500（下）基线原图

原始图片地址分别为天数基线和沐曦基线。官网基线用于统一赛题参照；本机原生基线和 BI-A7 当日对照用于分析实际代码收益，三种参照在正文中分别标明，不相互替代。

B 内核形状扫描与测量波动

本附录给出 paged decode attention 在 NSEG × 并发度上的实测分布，以及官方 benchmark 连续 4 次 run 的吞吐波动。数据来源分别为 `docs/experiments/a26/a26_sweep.log`（20 次重复取均值）和 `docs/baselines/metax-c500/raw_runs_baseline.csv`。



(a) 单层耗时（ms/层） (b) 有效带宽（GB/s）

图 20 NSEG × 并发度的实测分布（kv=16384）：红框为各自最优格

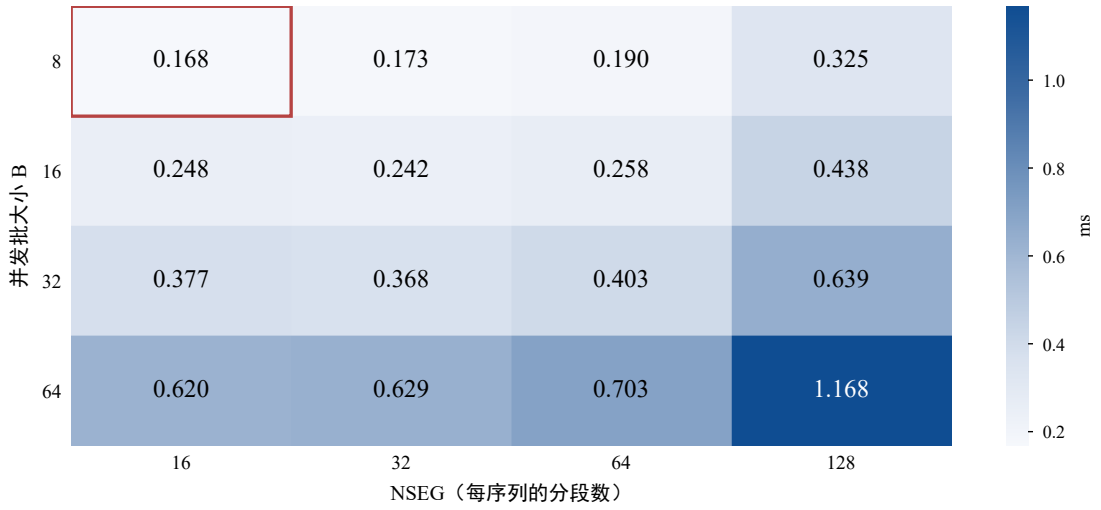


图 21 4k 场景下 NSEG × 并发度的单层耗时分布（kv=4096，ms/层）

官方 c64 形状下，NSEG=32 的有效带宽最高，为 515 GB/s，是实测 copy 参考 587 GB/s 的约 88%；继续增大 NSEG 会增加归并开销。小 batch 调整 NSEG 可获得 3%–7.4% 的收益，但官方两个用例均为 c64，因此当前实现保留 NSEG=32。

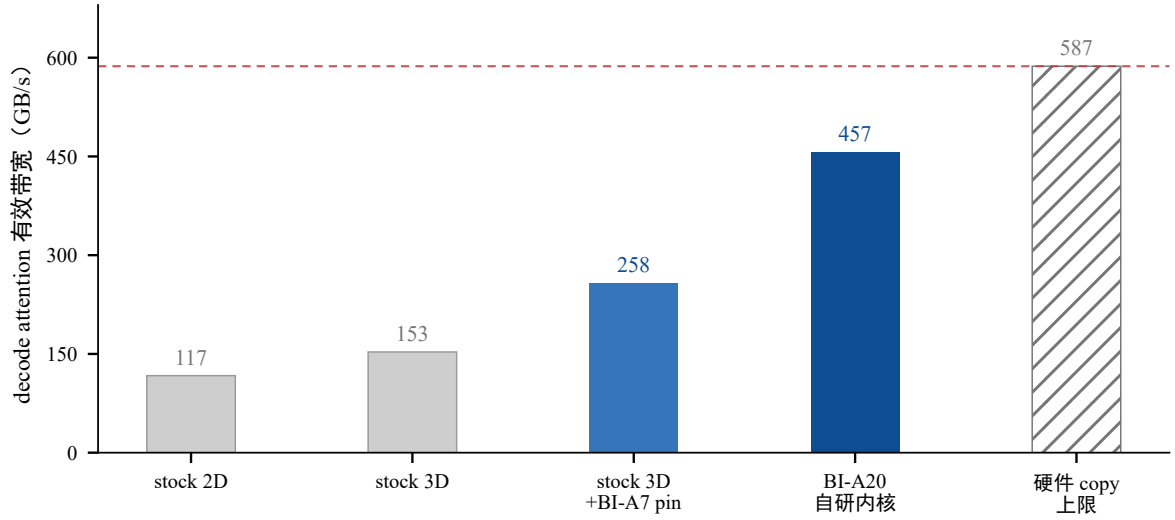


图 22 decode attention 从 stock 到自研内核的带宽演进

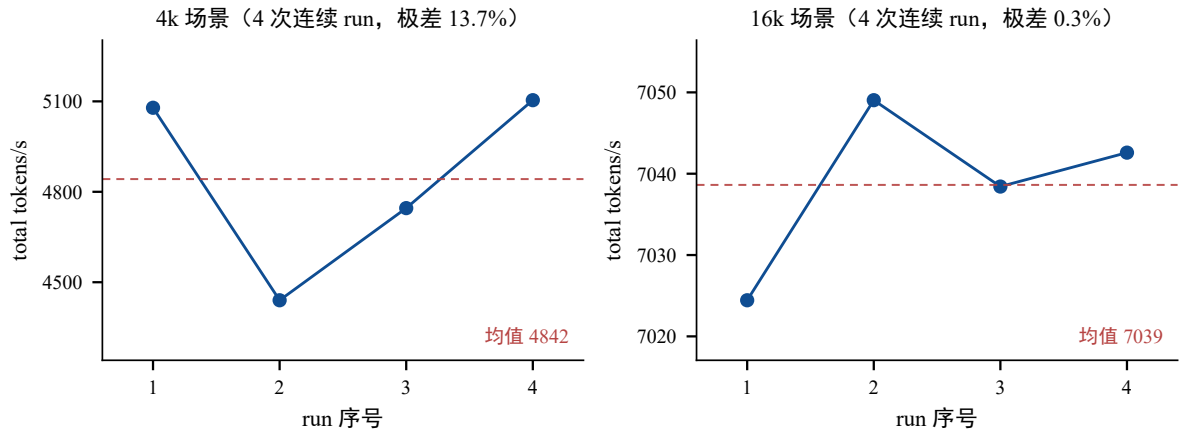


图 23 官方 benchmark 连续 4 次 run 的吞吐波动

官方 benchmark 对 4k 与 16k 均执行四轮，去掉首轮后取后三轮均值；历史 C500-opt 系列采用这一口径。C500 区间端点及个别旧 16k 记录为单次 `vllm bench serve` 输出，已另行说明，不与四轮聚合混称。优化项使用同日交错 A/B 比较，减少实例时段漂移的影响。