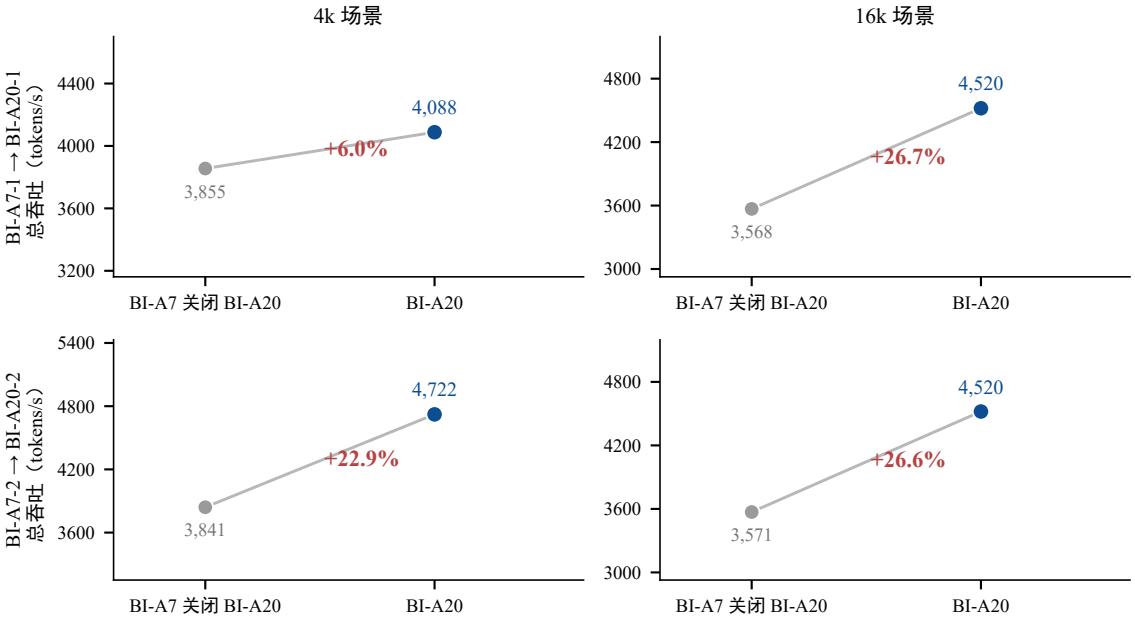
4k 场景
16k 场景
BI-A7-1 → BI-A20-1
总吞吐（tokens/s）
BI-A7-2 → BI-A20-2
总吞吐（tokens/s）
4400
4000
3600
3200
4800
4200
3600
3000
5400
4800
4200
3600
3,855
4,088
+6.0%
3,568
4,520
+26.7%
3,841
4,722
+22.9%
3,571
4,520
+26.6%
BI-A7 关闭 BI-A20
BI-A20