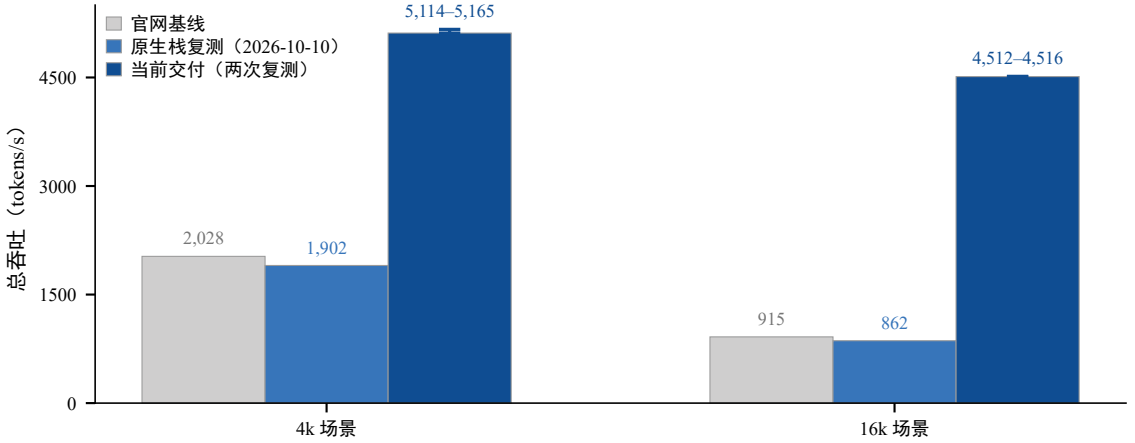
官网基线
原生栈复测（2026-10-10）
当前交付（两次复测）
总吞吐（tokens/s）
0
1500
3000
4500
2,028
1,902
5,114–5,165
915
862
4,512–4,516
4k 场景
16k 场景